

Étude de cas : Les influences déclarées dans les amendements de l’Assemblée Nationale



Étude de cas : Les influences déclarées dans les amendements de l’Assemblée Nationale

Objectif : classer automatiquement des amendements de la XVIIème législature selon qu’ils sont **sourcés** ou **non-sourcés**, avec ActiveTigger.

Plan de la session

Introduction : contexte, questions de recherche et données

1. Créer un projet
2. Définir son guide d’annotation
3. Annoter les jeux de données
4. Entraîner des modèles
5. Sélectionner un modèle
6. Évaluer le modèle
7. Prédire sur l’ensemble du jeu de données

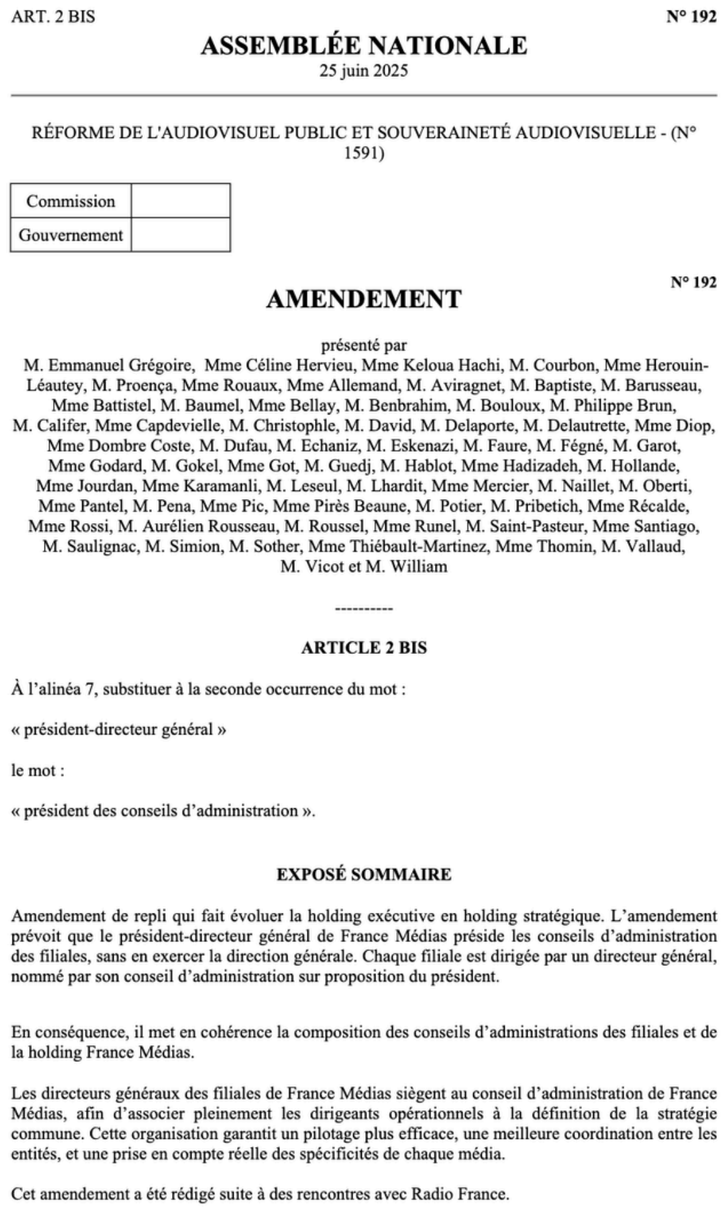


ActiveTigger

8. Quelques résultats
9. Discussion

Contexte

Un amendement résulte de nombreuses interactions.



ART. 2 BIS N° 192

ASSEMBLÉE NATIONALE

25 juin 2025

RÉFORME DE L'AUDIOVISUEL PUBLIC ET SOUVERAINETÉ AUDIOVISUELLE - (N° 1591)

Commission	
Gouvernement	

N° 192

AMENDEMENT

présenté par

M. Emmanuel Grégoire, Mme Céline Hervieu, Mme Keloua Hachi, M. Courbon, Mme Herouin-Léautey, M. Proença, Mme Rouaux, Mme Allemand, M. Aviragnet, M. Baptiste, M. Barusseau, Mme Battistel, M. Baumel, Mme Bellay, M. Benbrahim, M. Bouloux, M. Philippe Brun, M. Califer, Mme Capdevielle, M. Christophle, M. David, M. Delaporte, M. Delautrette, Mme Diop, Mme Dombre Coste, M. Dufau, M. Echaniz, M. Eskenazi, M. Faure, M. Fégné, M. Garot, Mme Godard, M. Gokel, Mme Got, M. Guedj, M. Hablot, Mme Hadizadeh, M. Hollande, Mme Jourdan, Mme Karamanli, M. Leseul, M. Lhardit, Mme Mercier, M. Naillet, M. Oberti, Mme Pantel, M. Pena, Mme Pic, Mme Pirès Beaune, M. Potier, M. Pribetich, Mme Récalde, Mme Rossi, M. Aurélien Rousseau, M. Roussel, Mme Runel, M. Saint-Pasteur, Mme Santiago, M. Saulignac, M. Simion, M. Sother, Mme Thiébault-Martinez, Mme Thomin, M. Vallaud, M. Vicot et M. William

---

ARTICLE 2 BIS

À l'alinéa 7, substituer à la seconde occurrence du mot :

« président-directeur général »

le mot :

« président des conseils d'administration ».

EXPOSÉ SOMMAIRE

Amendement de repli qui fait évoluer la holding exécutive en holding stratégique. L'amendement prévoit que le président-directeur général de France Médias préside les conseils d'administration des filiales, sans en exercer la direction générale. Chaque filiale est dirigée par un directeur général, nommé par son conseil d'administration sur proposition du président.

En conséquence, il met en cohérence la composition des conseils d'administrations des filiales et de la holding France Médias.

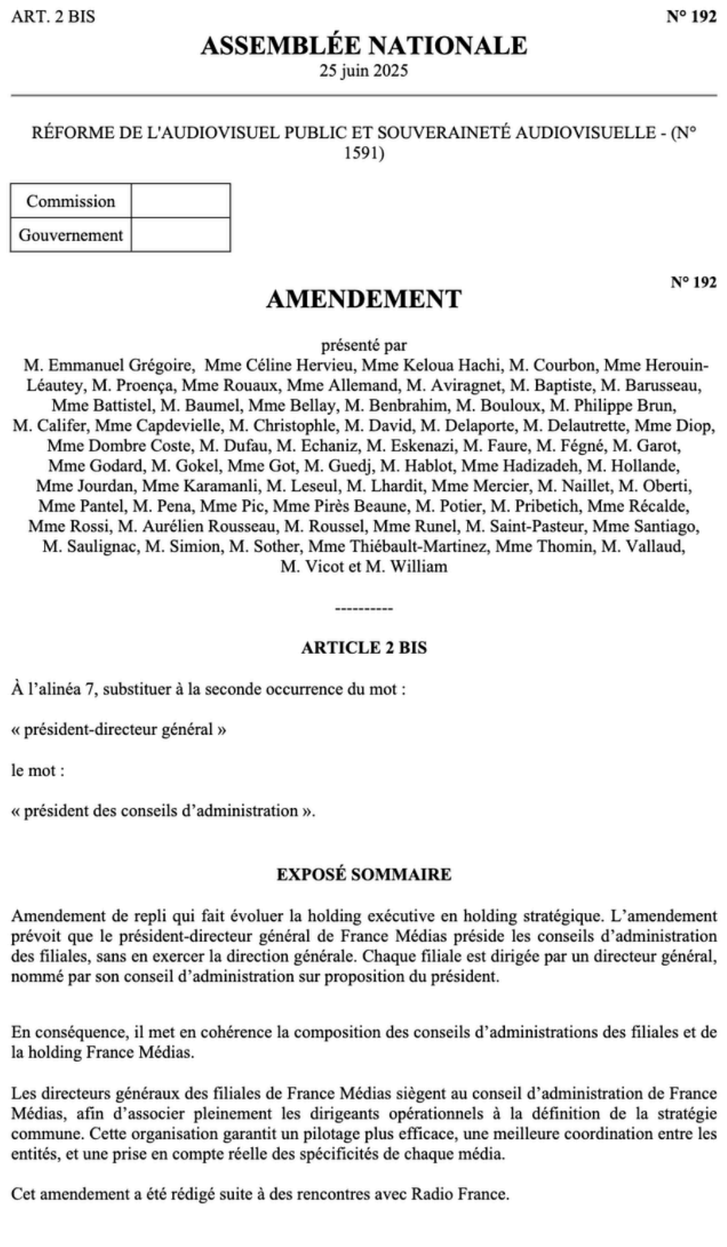
Les directeurs généraux des filiales de France Médias siègent au conseil d'administration de France Médias, afin d'associer pleinement les dirigeants opérationnels à la définition de la stratégie commune. Cette organisation garantit un pilotage plus efficace, une meilleure coordination entre les entités, et une prise en compte réelle des spécificités de chaque média.

Cet amendement a été rédigé suite à des rencontres avec Radio France.

Contexte

Un amendement résulte de nombreuses interactions.

Certains sont discutés avec ou proposés par un ou plusieurs groupe(s) d’intérêt.



ART. 2 BIS N° 192

ASSEMBLÉE NATIONALE

25 juin 2025

RÉFORME DE L'AUDIOVISUEL PUBLIC ET SOUVERAINETÉ AUDIOVISUELLE - (N° 1591)

Commission	
Gouvernement	

N° 192

AMENDEMENT

présenté par

M. Emmanuel Grégoire, Mme Céline Hervieu, Mme Keloua Hachi, M. Courbon, Mme Herouin-Léautey, M. Proença, Mme Rouaux, Mme Allemand, M. Aviragnet, M. Baptiste, M. Barusseau, Mme Battistel, M. Baumel, Mme Bellay, M. Benbrahim, M. Bouloux, M. Philippe Brun, M. Califer, Mme Capdevielle, M. Christophle, M. David, M. Delaporte, M. Delautrette, Mme Diop, Mme Dombre Coste, M. Dufau, M. Echaniz, M. Eskenazi, M. Faure, M. Fégné, M. Garot, Mme Godard, M. Gokel, Mme Got, M. Guedj, M. Hablot, Mme Hadizadeh, M. Hollande, Mme Jourdan, Mme Karamanli, M. Leseul, M. Lhardit, Mme Mercier, M. Naillet, M. Oberti, Mme Pantel, M. Pena, Mme Pic, Mme Pirès Beaune, M. Potier, M. Pribetich, Mme Récalde, Mme Rossi, M. Aurélien Rousseau, M. Roussel, Mme Runel, M. Saint-Pasteur, Mme Santiago, M. Saulignac, M. Simion, M. Sother, Mme Thiébault-Martinez, Mme Thomin, M. Vallaud, M. Vicot et M. William

---

ARTICLE 2 BIS

À l’alinéa 7, substituer à la seconde occurrence du mot :

« président-directeur général »

le mot :

« président des conseils d’administration ».

EXPOSÉ SOMMAIRE

Amendement de repli qui fait évoluer la holding exécutive en holding stratégique. L’amendement prévoit que le président-directeur général de France Médias préside les conseils d’administration des filiales, sans en exercer la direction générale. Chaque filiale est dirigée par un directeur général, nommé par son conseil d’administration sur proposition du président.

En conséquence, il met en cohérence la composition des conseils d’administrations des filiales et de la holding France Médias.

Les directeurs généraux des filiales de France Médias siègent au conseil d’administration de France Médias, afin d’associer pleinement les dirigeants opérationnels à la définition de la stratégie commune. Cette organisation garantit un pilotage plus efficace, une meilleure coordination entre les entités, et une prise en compte réelle des spécificités de chaque média.

Cet amendement a été rédigé suite à des rencontres avec Radio France.

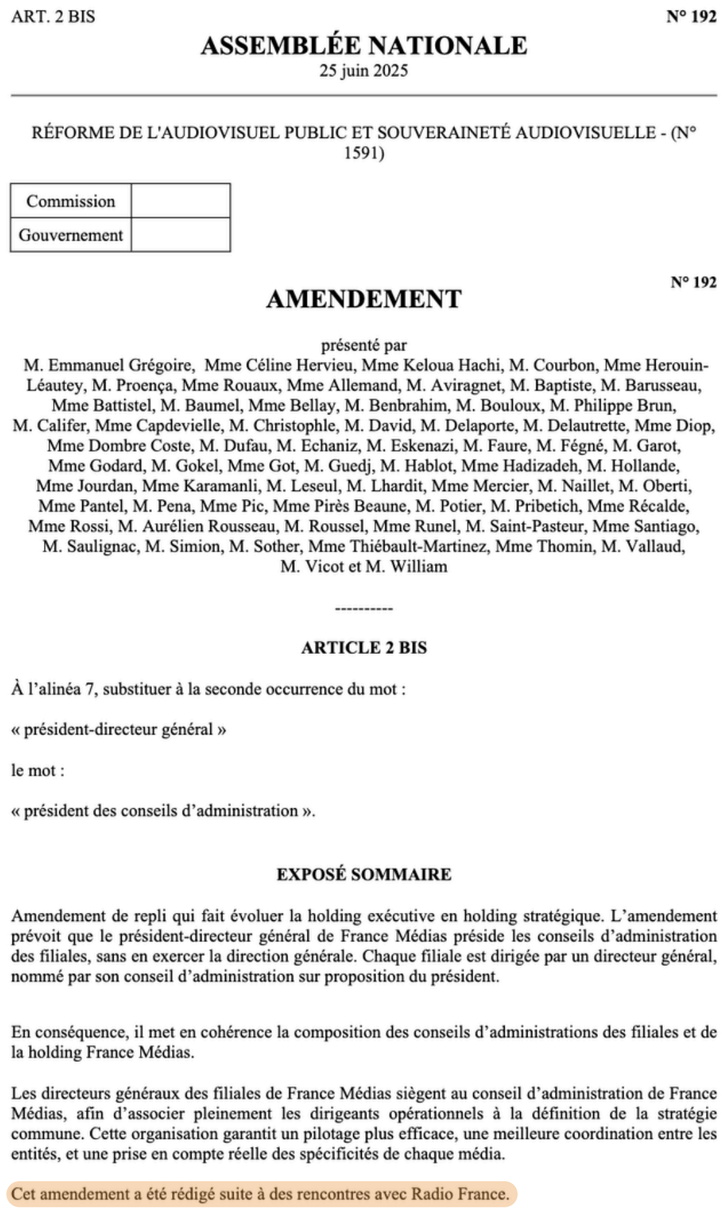
Contexte

Un amendement résulte de nombreuses interactions.

Certains sont discutés avec ou proposés par un ou plusieurs groupe(s) d'intérêt.

Sourcing des amendements : citer nommément ces groupes et la nature de leur influence sur la soumission d'un amendement donné dans l'exposé des motifs.

➔ "Bonne pratique" promue, mais non obligatoire



ART. 2 BIS N° 192

ASSEMBLÉE NATIONALE

25 juin 2025

RÉFORME DE L'AUDIOVISUEL PUBLIC ET SOUVERAINETÉ AUDIOVISUELLE - (N° 1591)

Commission	
Gouvernement	

N° 192

AMENDEMENT

présenté par

M. Emmanuel Grégoire, Mme Céline Hervieu, Mme Keloua Hachi, M. Courbon, Mme Herouin-Léautey, M. Proença, Mme Rouaux, Mme Allemand, M. Aviragnet, M. Baptiste, M. Barusseau, Mme Battistel, M. Baumel, Mme Bellay, M. Benbrahim, M. Bouloux, M. Philippe Brun, M. Califer, Mme Capdevielle, M. Christophle, M. David, M. Delaporte, M. Delautrette, Mme Diop, Mme Dombre Coste, M. Dufau, M. Echaniz, M. Eskenazi, M. Faure, M. Fégné, M. Garot, Mme Godard, M. Gokel, Mme Got, M. Guedj, M. Hablot, Mme Hadizadeh, M. Hollande, Mme Jourdan, Mme Karamanli, M. Leseul, M. Lhardit, Mme Mercier, M. Naillet, M. Oberti, Mme Pantel, M. Pena, Mme Pic, Mme Pirès Beaune, M. Potier, M. Pribetich, Mme Récalde, Mme Rossi, M. Aurélien Rousseau, M. Roussel, Mme Runel, M. Saint-Pasteur, Mme Santiago, M. Saulignac, M. Simion, M. Sother, Mme Thiébault-Martinez, Mme Thomin, M. Vallaud, M. Vicot et M. William

---

ARTICLE 2 BIS

À l'alinéa 7, substituer à la seconde occurrence du mot :

« président-directeur général »

le mot :

« président des conseils d'administration ».

EXPOSÉ SOMMAIRE

Amendement de repli qui fait évoluer la holding exécutive en holding stratégique. L'amendement prévoit que le président-directeur général de France Médias préside les conseils d'administration des filiales, sans en exercer la direction générale. Chaque filiale est dirigée par un directeur général, nommé par son conseil d'administration sur proposition du président.

En conséquence, il met en cohérence la composition des conseils d'administrations des filiales et de la holding France Médias.

Les directeurs généraux des filiales de France Médias siègent au conseil d'administration de France Médias, afin d'associer pleinement les dirigeants opérationnels à la définition de la stratégie commune. Cette organisation garantit un pilotage plus efficace, une meilleure coordination entre les entités, et une prise en compte réelle des spécificités de chaque média.

Cet amendement a été rédigé suite à des rencontres avec Radio France.

sourcing !

Contexte : structure d’un amendement

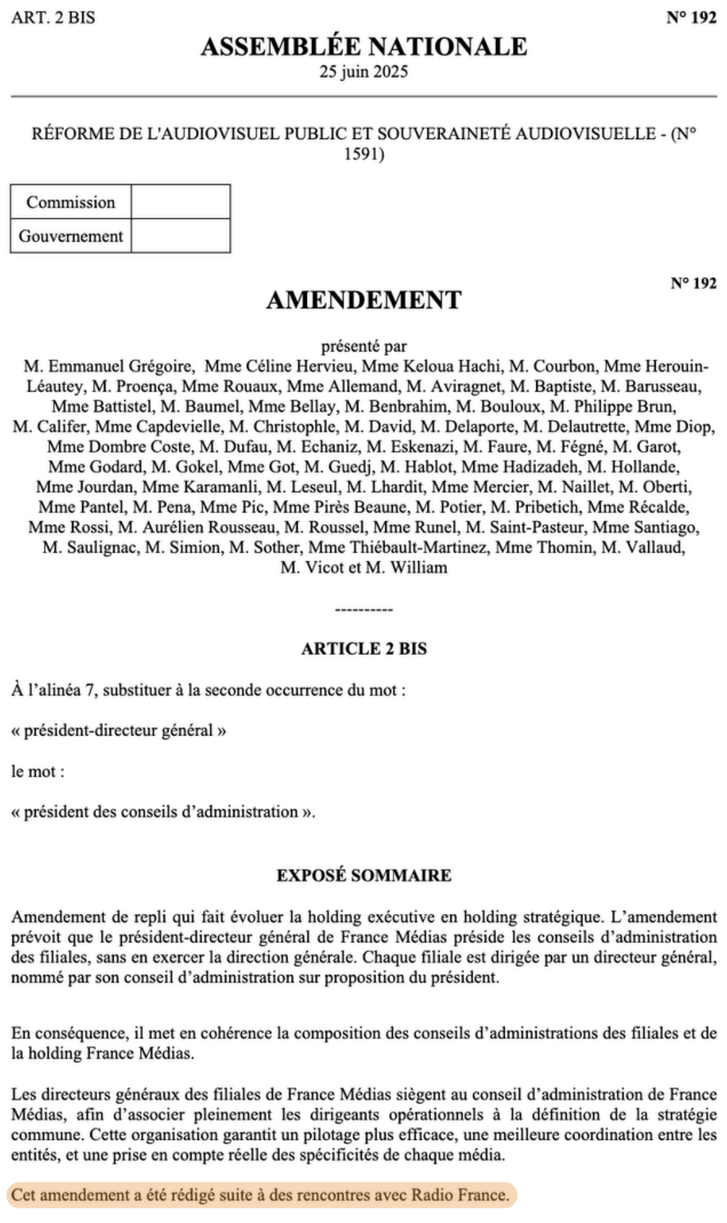
Date, projet de loi, identifiants

Autrices/Auteurs

Substance

Exposé sommaire des motifs

C’est ici que le **sourcing** peut se trouver ⟶



ART. 2 BIS N° 192

ASSEMBLÉE NATIONALE

25 juin 2025

RÉFORME DE L'AUDIOVISUEL PUBLIC ET SOUVERAINETÉ AUDIOVISUELLE - (N° 1591)

Commission	
Gouvernement	

N° 192

AMENDEMENT

présenté par

M. Emmanuel Grégoire, Mme Céline Hervieu, Mme Keloua Hachi, M. Courbon, Mme Herouin-Léautey, M. Proença, Mme Rouaux, Mme Allemand, M. Aviragnet, M. Baptiste, M. Barusseau, Mme Battistel, M. Baumel, Mme Bellay, M. Benbrahim, M. Bouloux, M. Philippe Brun, M. Califer, Mme Capdevielle, M. Christophle, M. David, M. Delaporte, M. Delautrette, Mme Diop, Mme Dombre Coste, M. Dufau, M. Echaniz, M. Eskenazi, M. Faure, M. Fégné, M. Garot, Mme Godard, M. Gokel, Mme Got, M. Guedj, M. Hablot, Mme Hadizadeh, M. Hollande, Mme Jourdan, Mme Karamanli, M. Leseul, M. Lhardit, Mme Mercier, M. Naillet, M. Oberti, Mme Pantel, M. Pena, Mme Pic, Mme Pirès Beaune, M. Potier, M. Pribetich, Mme Récalde, Mme Rossi, M. Aurélien Rousseau, M. Roussel, Mme Runel, M. Saint-Pasteur, Mme Santiago, M. Saulignac, M. Simion, M. Sother, Mme Thiébault-Martinez, Mme Thomin, M. Vallaud, M. Vicot et M. William

---

ARTICLE 2 BIS

À l’alinéa 7, substituer à la seconde occurrence du mot :

« président-directeur général »

le mot :

« président des conseils d’administration ».

EXPOSÉ SOMMAIRE

Amendement de repli qui fait évoluer la holding exécutive en holding stratégique. L’amendement prévoit que le président-directeur général de France Médias préside les conseils d’administration des filiales, sans en exercer la direction générale. Chaque filiale est dirigée par un directeur général, nommé par son conseil d’administration sur proposition du président.

En conséquence, il met en cohérence la composition des conseils d’administrations des filiales et de la holding France Médias.

Les directeurs généraux des filiales de France Médias siègent au conseil d’administration de France Médias, afin d’associer pleinement les dirigeants opérationnels à la définition de la stratégie commune. Cette organisation garantit un pilotage plus efficace, une meilleure coordination entre les entités, et une prise en compte réelle des spécificités de chaque média.

Cet amendement a été rédigé suite à des rencontres avec Radio France.

La recherche

Méthodologiquement : Peut-on identifier les amendements sourcés sur un large corpus, sachant que les termes évoqués varient ?

La recherche

Méthodologiquement : Peut-on identifier les amendements sourcés sur un large corpus, sachant que les termes évoqués varient ?

Cela nous permettrait de répondre à une série de questions :

- La pratique est-elle répandue ? (RQ1)
- La pratique est-elle uniforme entre les groupes politiques ? (RQ2)
- La pratique évolue-t-elle dans le temps ? (RQ3)

Données

Ne pas hésiter à passer du temps à **réfléchir** aux données et à les **préparer**.

Données

Ne pas hésiter à passer du temps à **réfléchir** aux données et à les **préparer**.

Données de départ (**123 224 amendements x 25 col**) : tous les amendements de la XVIIème législature de l'Assemblée Nationale jusqu'au 21-07-2026 (XML puis CSV).

Données

Ne pas hésiter à passer du temps à **réfléchir** aux données et à les **préparer**.

Données de départ (123 224 amendements x 25 col) : tous les amendements de la XVIIème législature de l'Assemblée Nationale jusqu'au 21-07-2026 (XML puis CSV).

avec    ...

Retirer les variables inutiles,

les amendements dont l'exposé sommaire est vide,

éviter les annotations contradictoires ← les amendements dont l'exposé sommaire est dupliqué,

les amendements de +1024 tokens.

↳ fenêtre de contexte maximale pour le modèle utilisé ici (n=1024)

Focus : quelle échelle choisir pour ses données ?

Annoter les phrases ou les amendements ? Cinq questions pour nous aider (cf. FAQ) :

1. **Objet de la recherche ?**
2. **Homogénéité thématique ?**
3. **Distribution des labels ?**
4. **Modèle adapté aux données avec fenêtre de contexte appropriée ?**
5. **Puissance de calcul suffisante ?**

Le point 3 nous amène à choisir le niveau des **amendements**.

Données

Données préparées (65 388 amendements x 2 col) : amendements de la XVIIème législature de l'Assemblée Nationale dont l'exposé sommaire est unique, non vide et d'une longueur inférieure à 1024 tokens.

shape: (65_388, 2)

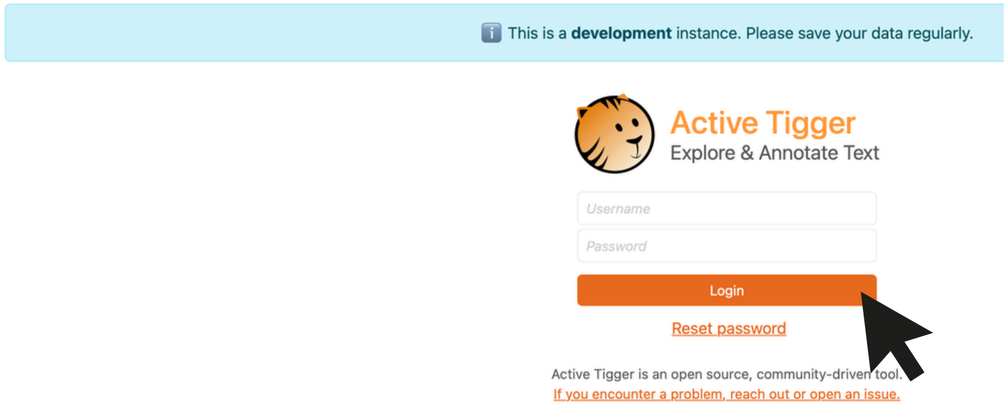
uid	expose_sommaire
str	str
"AMANR5L17PO838901B1906P2D1N002...	"Cet amendement augmente le bud...
"AMANR5L17PO838901B1906P1D1N001...	"En France, le tabagisme représ...
"AMANR5L17PO838901B1906P1D1N000...	"Cet amendement vise à rehausse...
"AMANR5L17PO838901B2141P0D1N000...	"Afin de répondre aux enjeux cr...
"AMANR5L17PO838901B1906P2D1N000...	"Le présent amendement des dépu...
...	...
"AMANR5L17PO838901BTC1437P0D1N0...	"Le législateur a interdit en 2...
"AMANR5L17PO59048B2247P0D1N0013...	"Sur proposition du collectif C...
"AMANR5L17PO838901B1906P2D1N001...	"Le CNPF est l'établissement pu...
"AMANR5L17PO838901B0325P0D1N001...	"Cet amendement vise à augmente...
"AMANR5L17PO849474B0481P0D1N001...	"La procédure de sanction simpl...

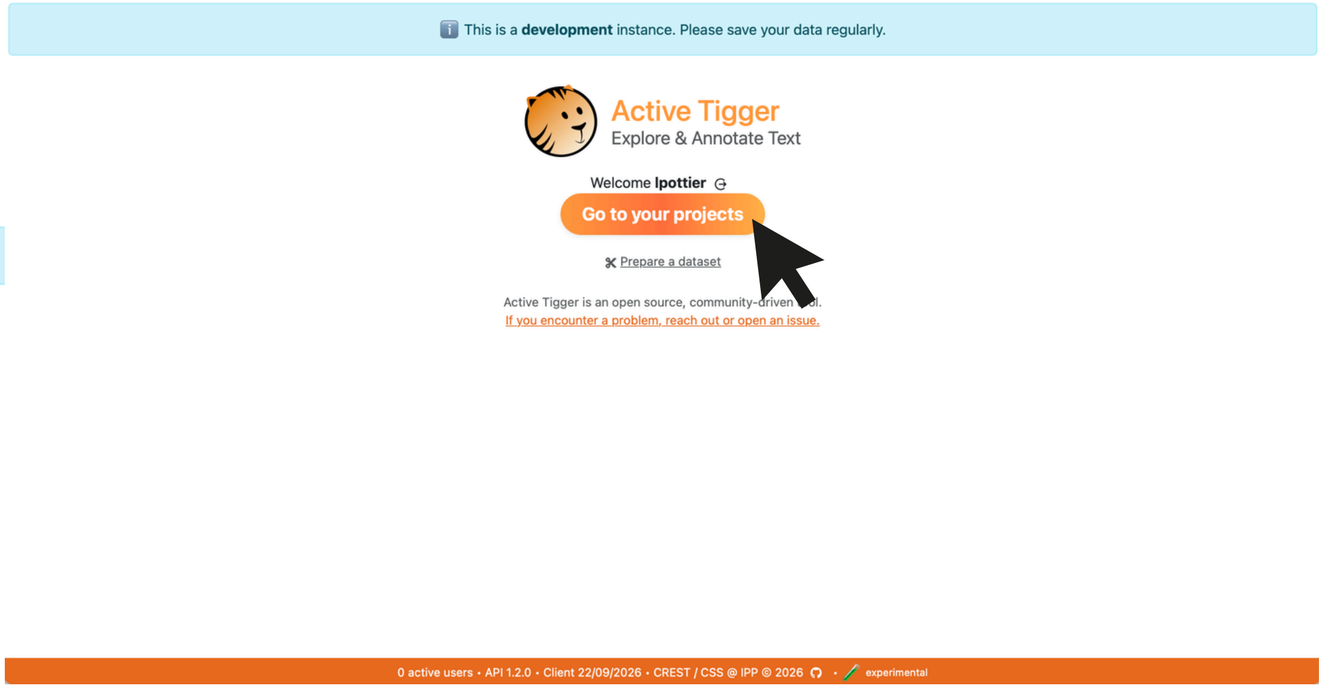
identifiant unique texte

Étape 0 : se connecter à ActiveTigger

Adresse : app.activetigger.com

Identifiants : voir lien

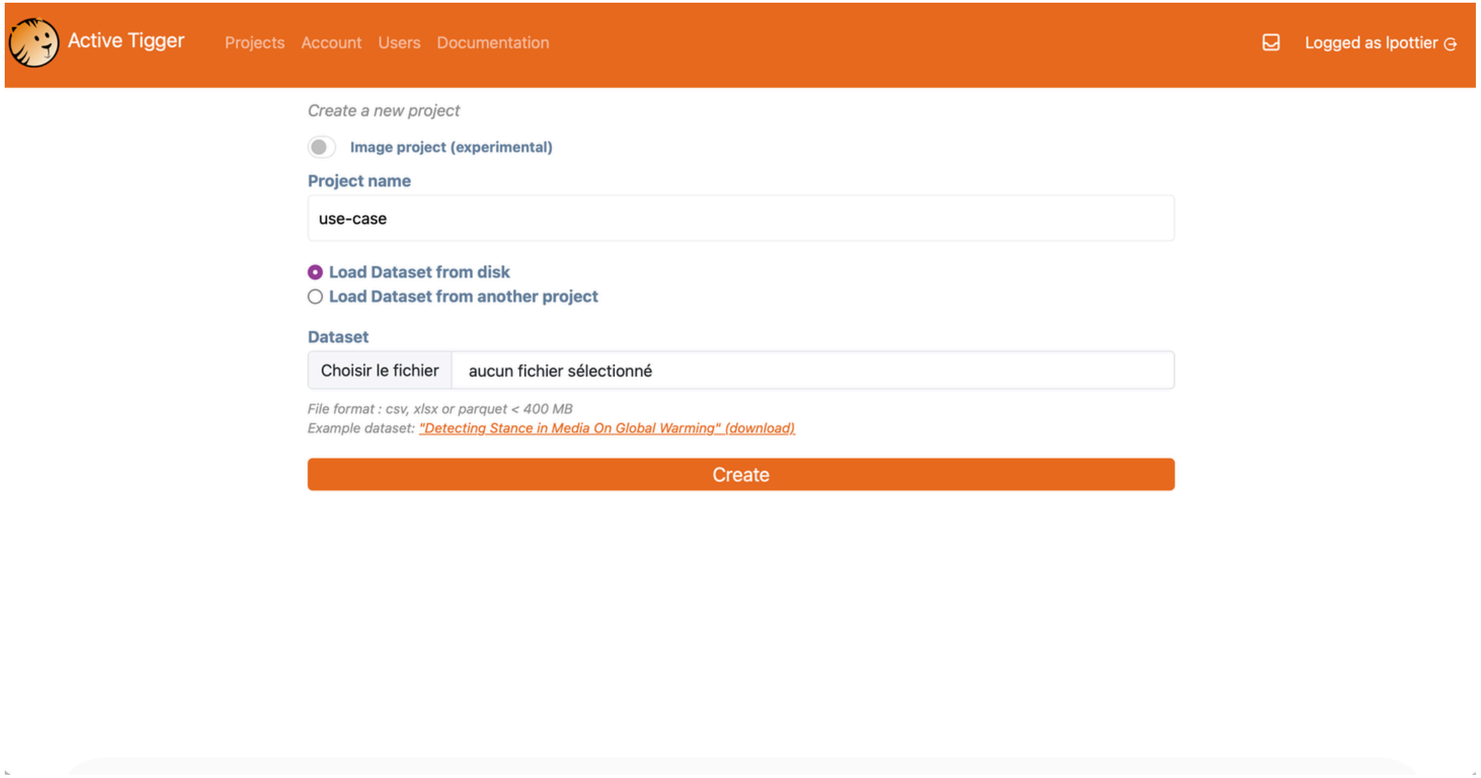




Étape 1 : créer un projet

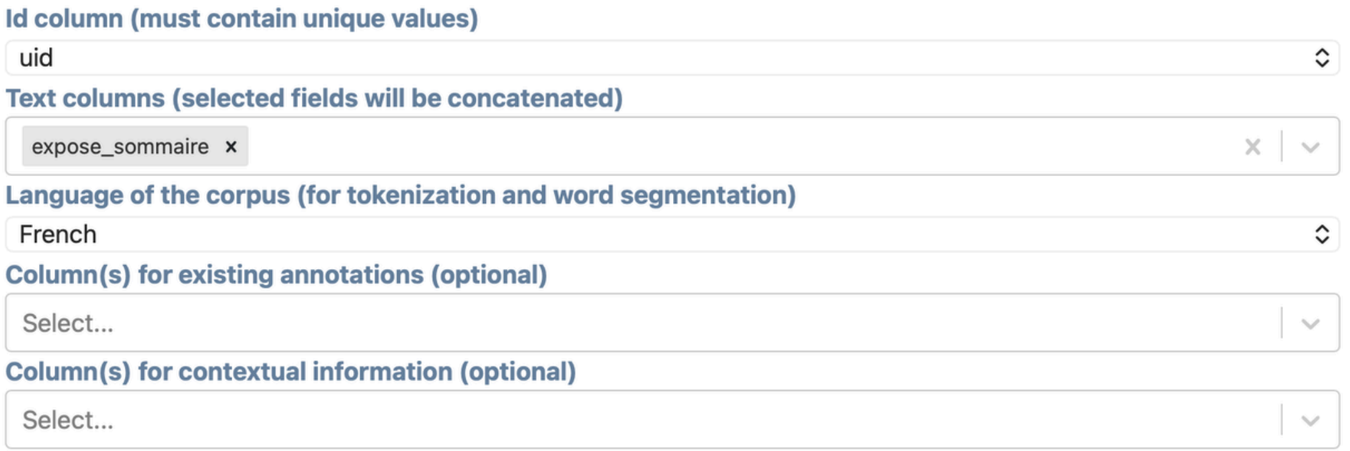
1. Cliquer sur 

2. Choisir le nom du projet et sélectionner le dataset depuis votre disque



Étape 1 : créer un projet

3. Remplir les informations demandées sur notre dataset



 Étape 1 : créer un projet

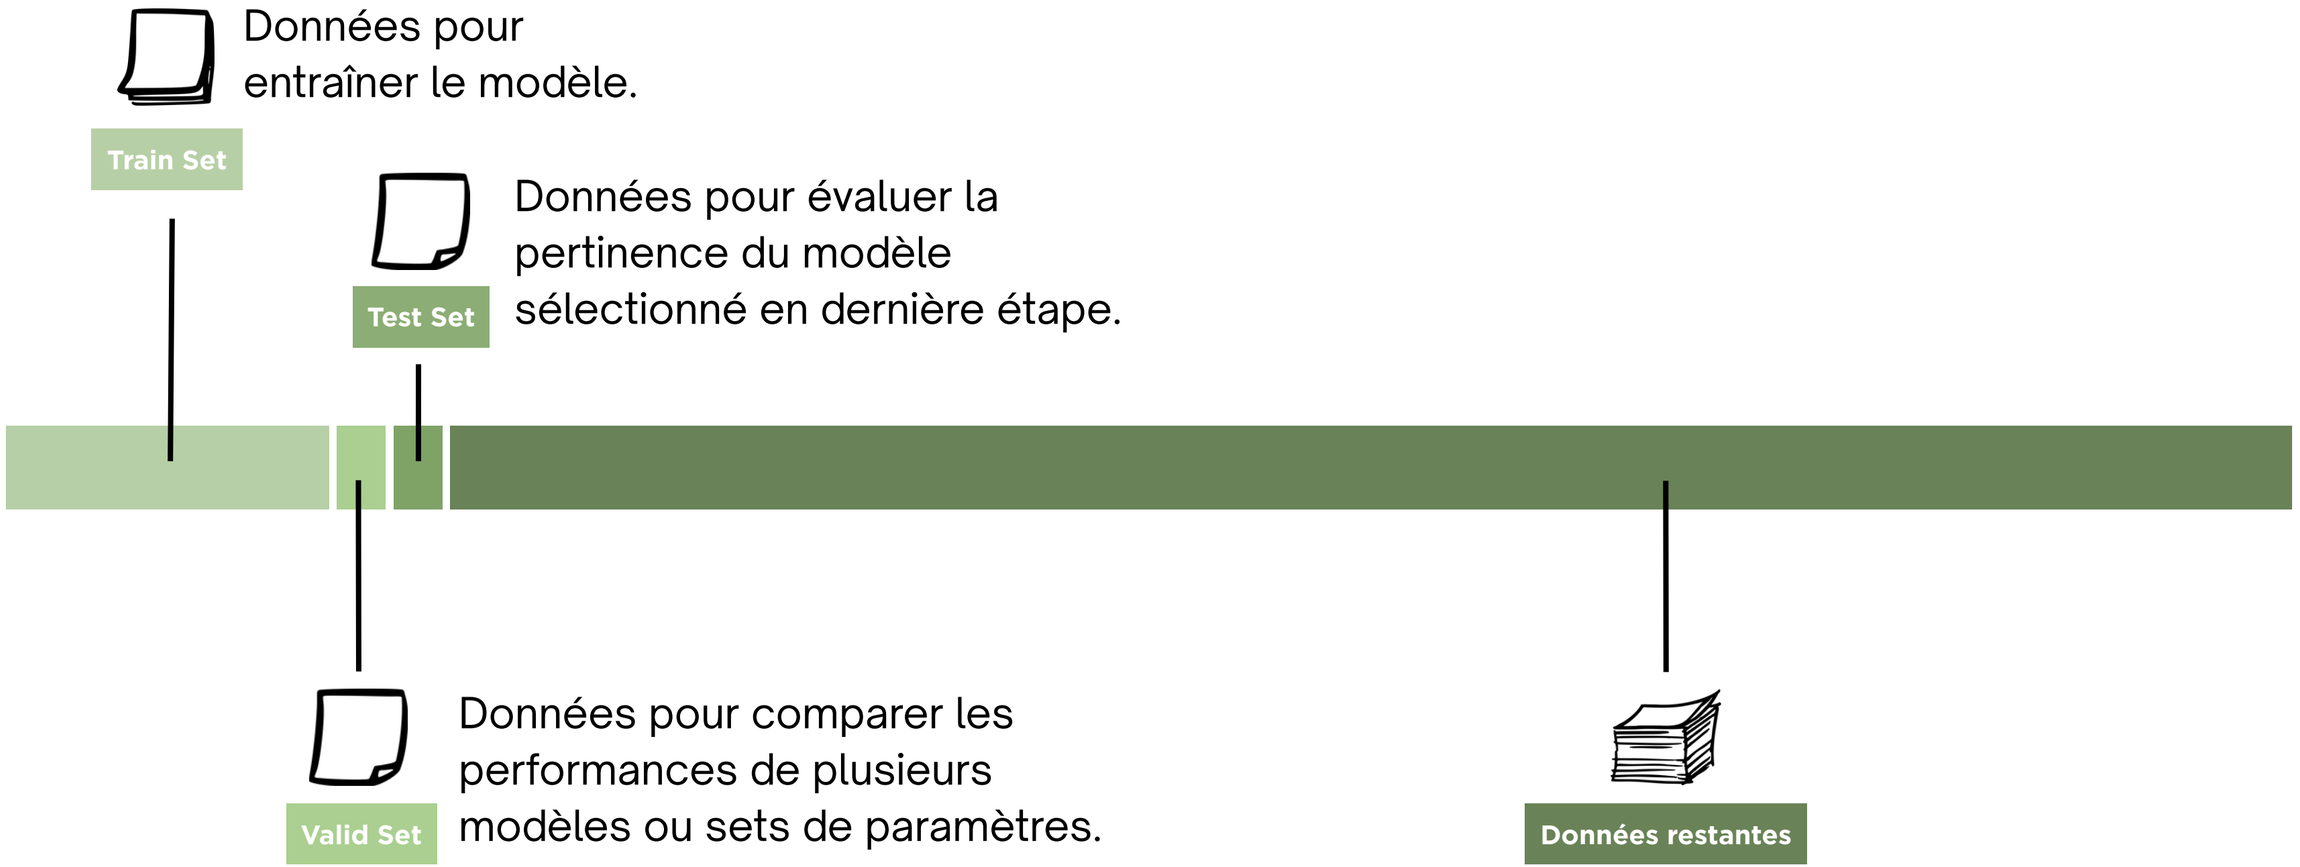
4. Sélectionner la taille des **train**, **validation** et **test sets**.

Focus : train, validation et test sets

Jeu de données importé

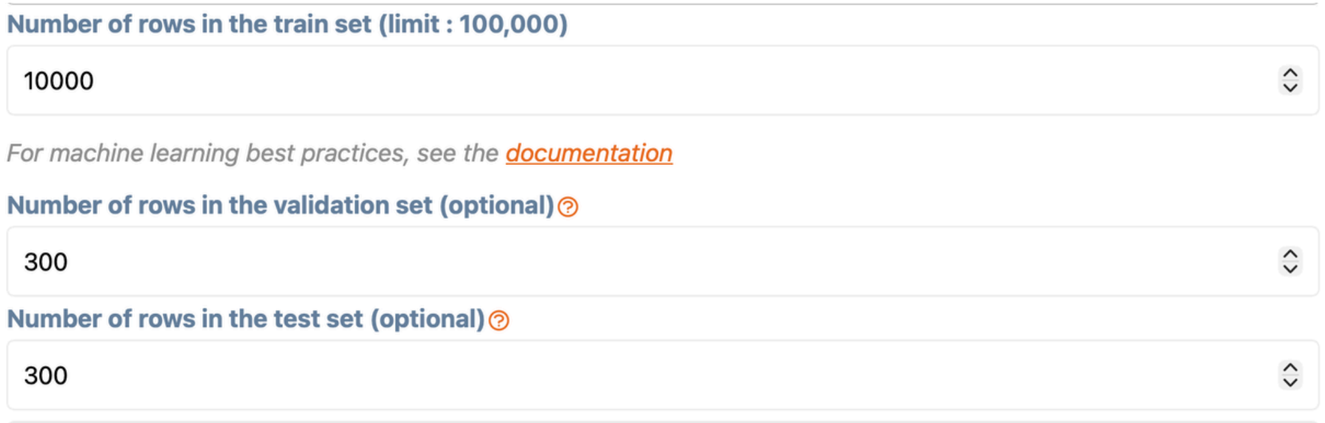


Focus : train, validation et test sets



Étape 1 : créer un projet

4. Sélectionner la taille des **train**, **validation** et **test sets**.

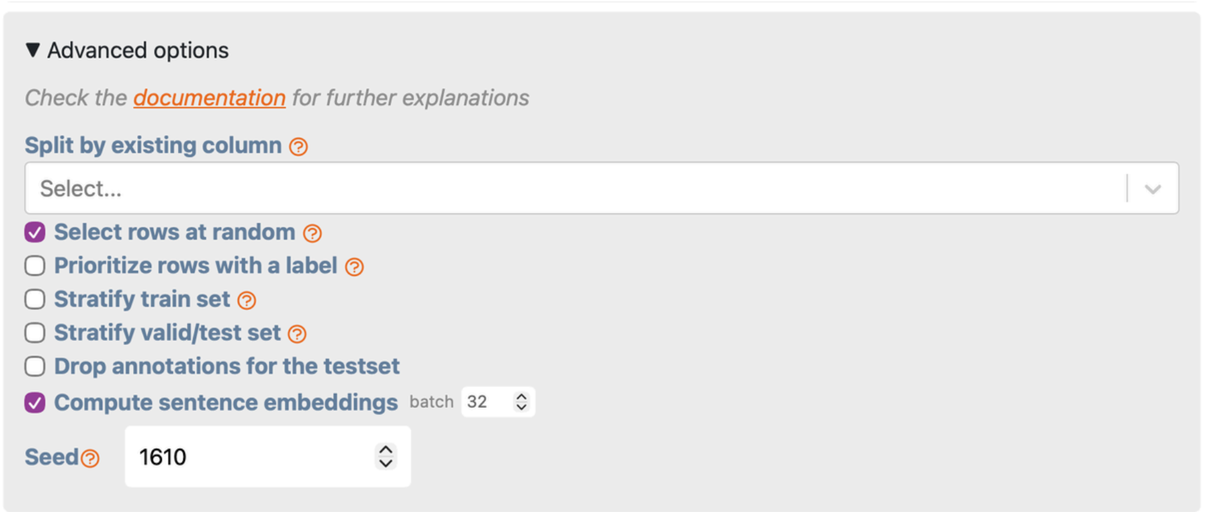


- Train : défaut 10 000 (tout ne sera pas annoté)
- Valid, Test : commençons par 300.

    Le label “source” a une prévalence de 8-9%, on aura ≈26 items par set.

Étape 1 : créer un projet

(5-Optionnel.) Possibilité de sélectionner des options avancées, cf. documentation.



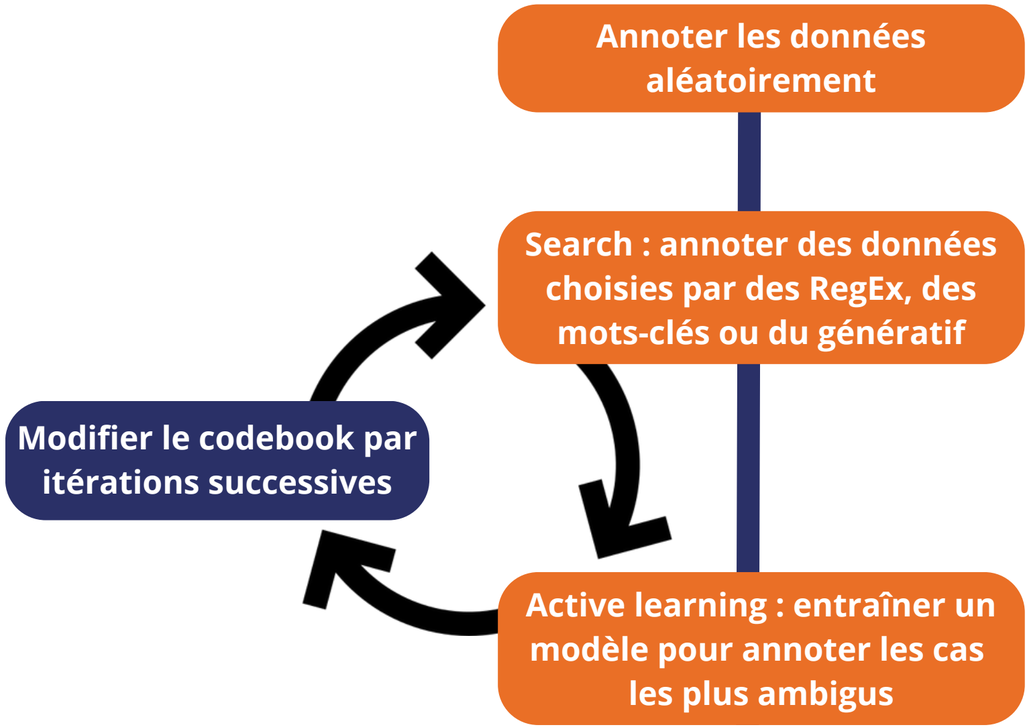
6. Cliquer sur 

Votre projet est créé !

Rappel : le workflow d’un projet ActiveTigger

Étape 1 : Création du projet

Étape 2 : Définir son guide d’annotation



Étape 3 : Annoter les jeux de données



Étape 4 : Entraîner des modèles



Étape 5 : Sélectionner un modèle



Étape 6 : Évaluer le modèle



Étape 7 : Prédire sur l’ensemble des données



Étape 2 : définir son guide d’annotation

Pour pouvoir annoter, il nous faut créer un premier codebook.

➔ Quelles catégories (=labels, étiquettes) pourrions-nous créer ?
➔ Avec quelles définitions ?

Chaque amendement doit entrer dans **une et une seule** catégorie.

Étape 2 : définir son guide d’annotation

Deux catégories : “source” / “non-source”

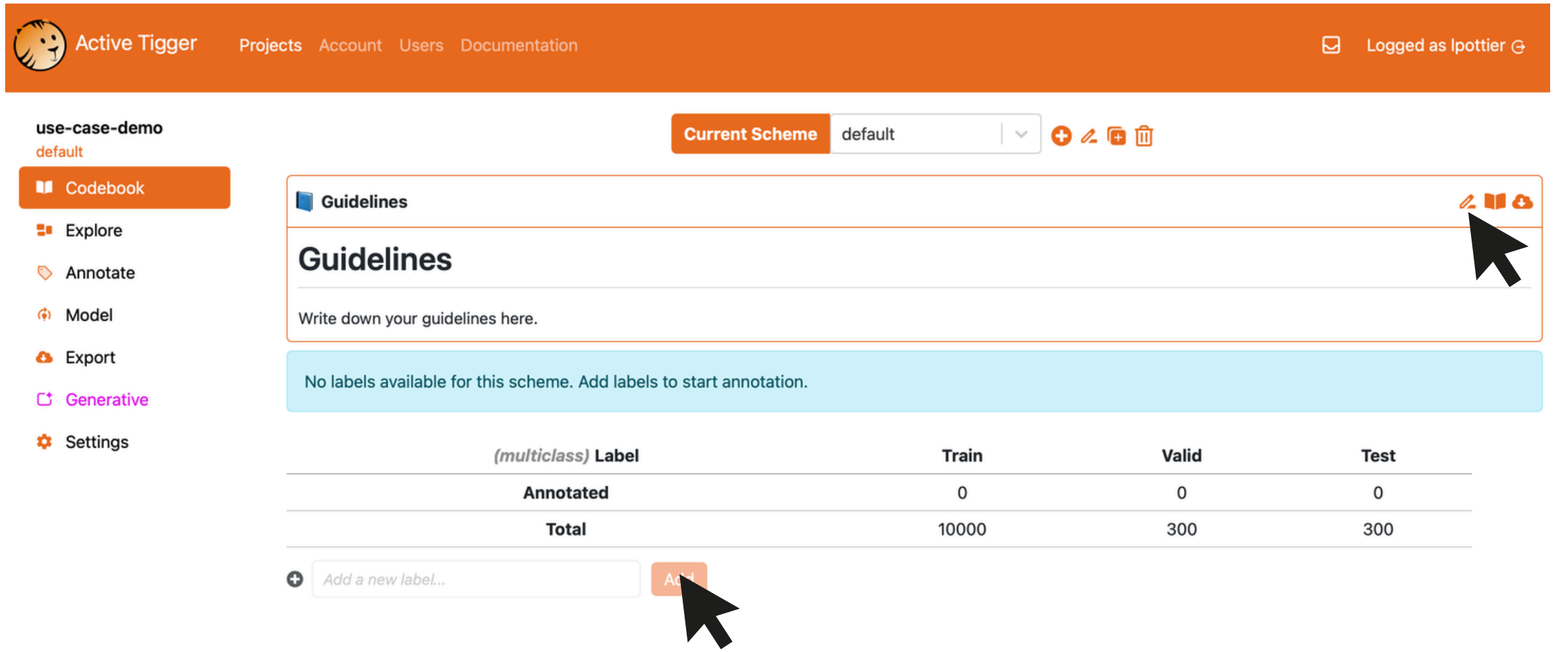
Partons d’une définition simple (et un peu naïve) :

1. Un amendement est **source** quand il a été travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle.

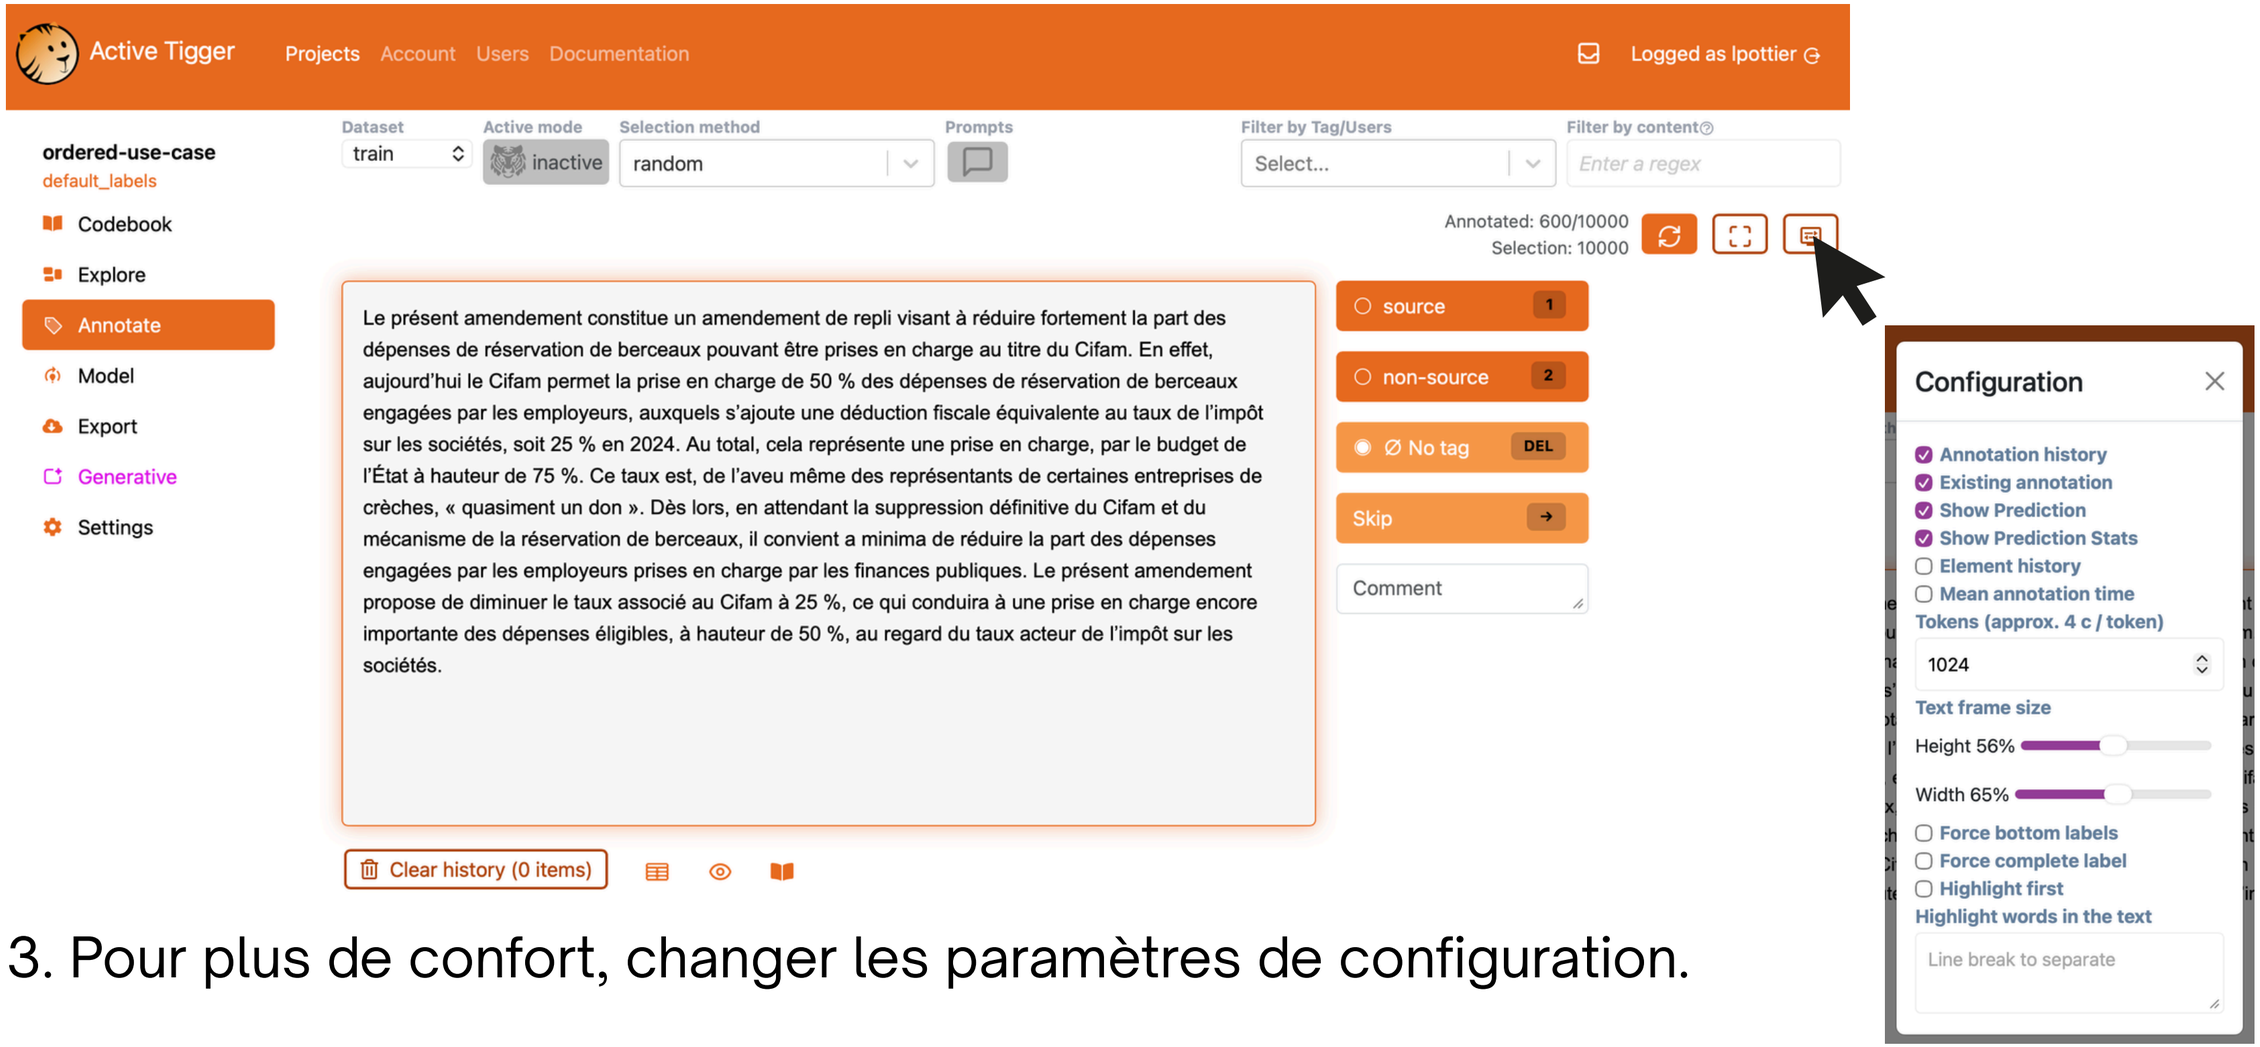
   Un amendement est **non-source** dans tous les autres cas.

Étape 2 : définir son guide d’annotation

1. Créer les deux labels (source et non-source) : les écrire puis cliquer sur Add.
2. Rédiger le codebook : cliquer sur l’icône stylo et ajouter le texte.



Étape 2 : définir son guide d’annotation



3. Pour plus de confort, changer les paramètres de configuration.

Étape 2 : définir son guide d’annotation

4. C’est parti : annotons une dizaine d’amendements de façon aléatoire.
On apprend à connaître nos données.

Étape 2 : définir son guide d’annotation

Annoter de façon augmentée

Search

Active learning

Étape 2 : définir son guide d’annotation

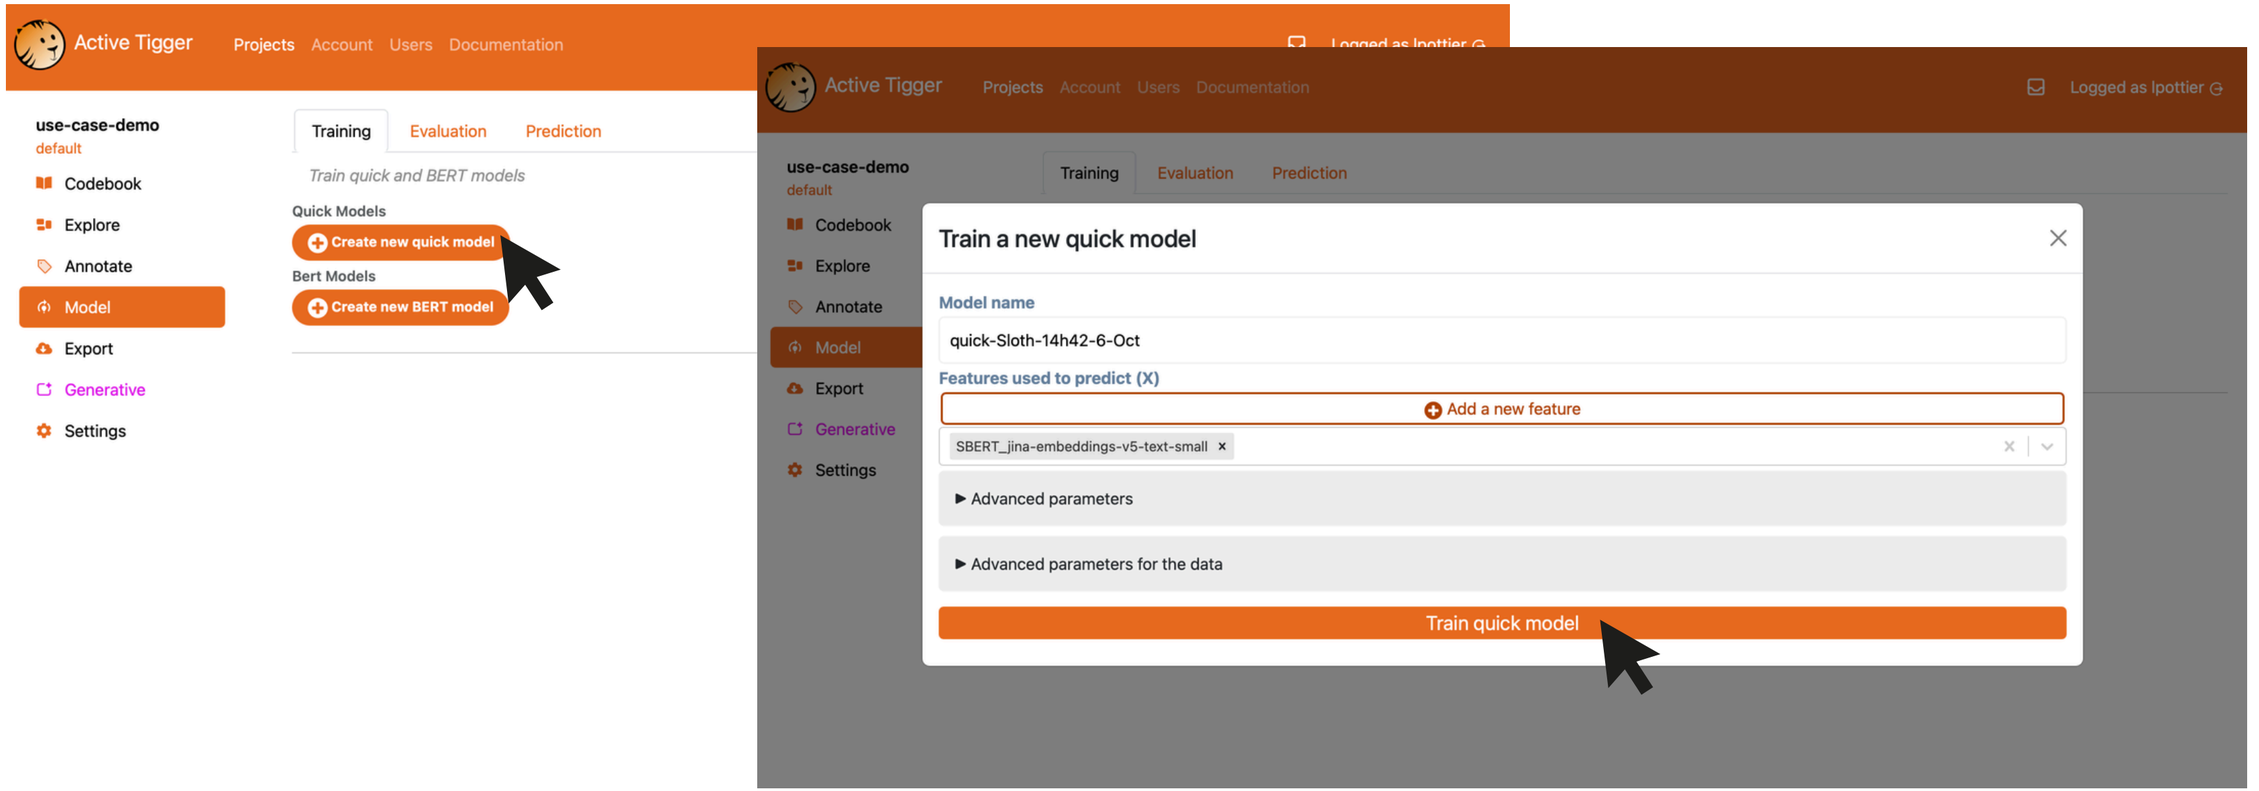
On remarque que le sourcing se matérialise souvent par la présence de la phrase suivante : “Cet amendement a été travaillé avec xx”.



5. **Search** : annotons des amendements qui contiennent “travaillé avec”.

Étape 2 : définir son guide d’annotation

6. **Active learning** : entraînons un premier quick model



Étape 2 : définir son guide d’annotation

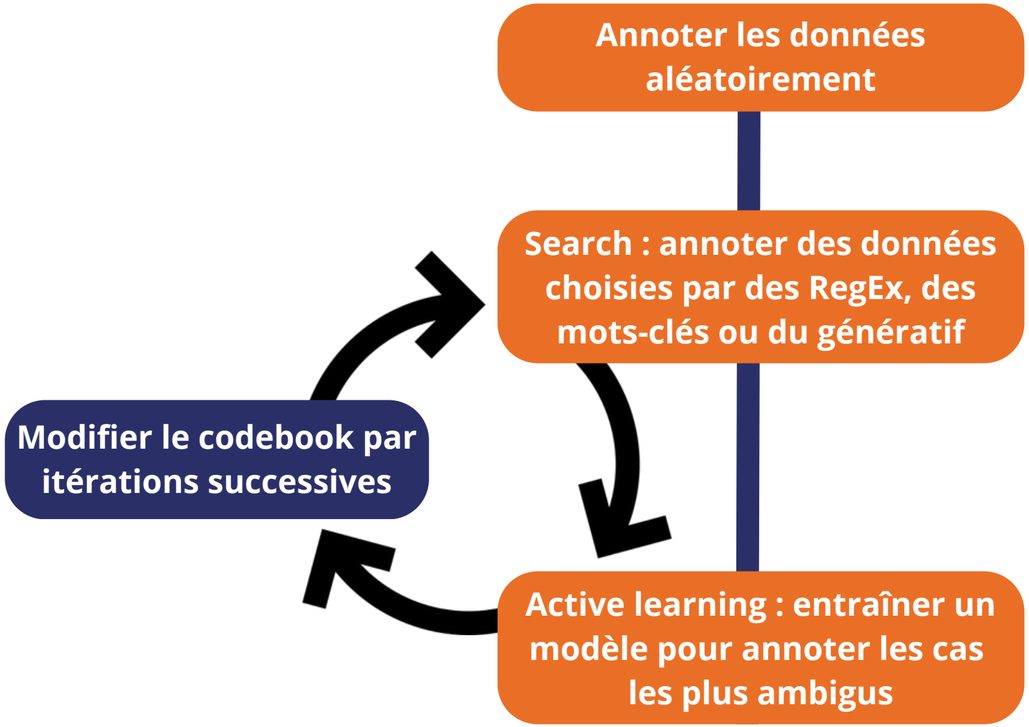
6. **Active learning** : annotons quelques d’amendements.



Nous pourrons ensuite entraîner d’autres modèles pour améliorer les prédictions et donc la sélection des cas difficiles.

Étape 2 : définir son guide d’annotation

Au fil des annotations, on rencontre des cas difficiles qui font évoluer notre codebook.



Étape 2 : définir son guide d’annotation

DÉPART

1

Un amendement est **source** quand il a été travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle.

Un amendement est **non-source** dans tous les autres cas.

Étape 2 : définir son guide d’annotation

DÉPART

1 Un amendement est **source** quand il a été travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle.

Un amendement est **non-source** dans tous les autres cas.

(…) **Cet amendement a été suggéré par la Fondation pour la Nature et l’Homme.**

Étape 2 : définir son guide d’annotation

DÉPART

1

Un amendement est **source** quand il a été travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle.

Un amendement est **non-source** dans tous les autres cas.

(…) **Cet amendement a été suggéré par la Fondation pour la Nature et l’Homme.**

PB : suggérer ≠ travailler avec

Étape 2 : définir son guide d’annotation

DÉPART

1 Un amendement est **source** quand il a été travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle.

Un amendement est **non-source** dans tous les autres cas.

(…) **Cet amendement a été suggéré par la Fondation pour la Nature et l’Homme.**

PB : suggérer ≠ travailler avec

2 *Modif*: Un amendement est source quand il a été **suggéré par ou** travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle.

Étape 2 : définir son guide d’annotation

Cet amendement **adopté en commission du développement durable** propose (…)

Étape 2 : définir son guide d’annotation

Cet amendement **adopté en commission du développement durable** propose (…)

PB : source explicite mais pas un représentant d’intérêt.

=> Redéfinir la RQ vers l’identification de l’origine des amendements, quelle qu’elle soit ? Choix : non.

Étape 2 : définir son guide d’annotation

Cet amendement **adopté en commission du développement durable** propose (…)

Le présent amendement, **soutenu par l’Association des maires de France (AMF)**, vise à supprimer (…)

PB : source explicite mais pas un représentant d’intérêt.

=> Redéfinir la RQ vers l’identification de l’origine des amendements, quelle qu’elle soit ? Choix : non.

Étape 2 : définir son guide d’annotation

Cet amendement **adopté en commission du développement durable** propose (…)

PB : source explicite mais pas un représentant d’intérêt.
=> Redéfinir la RQ vers l’identification de l’origine des amendements, quelle qu’elle soit ? Choix : non.

Le présent amendement, **soutenu par l’Association des maires de France (AMF)**, vise à supprimer (…)

PB : associations d’élus et élues sont-elles des “lobbies” ? Choix : non (appui sur HATVP).

Étape 2 : définir son guide d’annotation

Cet amendement **adopté en commission du développement durable** propose (...)

PB : source explicite mais pas un représentant d’intérêt.
=> Redéfinir la RQ vers l’identification de l’origine des amendements, quelle qu’elle soit ? Choix : non.

Le présent amendement, **soutenu par l’Association des maires de France (AMF)**, vise à supprimer (...)

PB : associations d’élus et élues sont-elles des “lobbies” ? Choix : non (appui sur HATVP).

3 *Ajout:* On entend par "représentant d’intérêt" un groupe ou une institution extérieure à la représentation politique, représentant des intérêts privés, conformément à la définition de la HATVP.

Étape 2 : définir son guide d’annotation

(…) Cet amendement a été élaboré en concertation **avec la profession.**

(…) Cet amendement a été travaillé **avec le collectif** oui au train de nuit.

Étape 2 : définir son guide d’annotation

(…) Cet amendement a été élaboré en concertation **avec la profession.**

(…) Cet amendement a été travaillé **avec le collectif** oui au train de nuit.

PB : “profession” et “collectif” ne rentrent pas dans la définition de la HATVP.

=> Les inclure ? Choix : oui.

Étape 2 : définir son guide d’annotation

(...) Cet amendement a été élaboré en concertation **avec la profession.**

(...) Cet amendement a été travaillé **avec le collectif** oui au train de nuit.

PB : “profession” et “collectif” ne rentrent pas dans la définition de la HATVP.

=> Les inclure ? Choix : oui.

4

Modif: On entend par "représentant d’intérêt" un groupe ou une institution extérieure à la représentation politique, représentant des intérêts privés.

Ajout: Cette définition reprend celle de la HATVP mais élargit son champ en n'exigeant pas une personnalité morale du représentant d'intérêt.

Étape 2 : définir son guide d’annotation

Codebook final

Guidelines

On définit deux étiquettes : **source** et **non-source**.

- Un amendement est **source** quand il a été suggéré par ou travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle. On entend par "représentant d’intérêt" un groupe ou une institution extérieure à la représentation politique, représentant des intérêts privés.

Cette définition reprend celle de la Haute Autorité pour la Transparence de la Vie Publique (HATVP) (à consulter ici) mais élargit son champ en n'exigeant pas une personnalité morale du représentant d'intérêt. Les collectifs ou une profession, par exemple, sont donc inclus.

- Un amendement est **non-source** dans tous les autres cas.

Exemples :

- “(...) Cet amendement a été travaillé avec la FNSEA.” est **source**.

  Il est explicitement mentionné que l’amendement est issu d’une collaboration avec un syndicat professionnel.

- “(...) Cet amendement est un amendement de repli proposé par L214. (...) ” est **source**.

  Il est explicitement mentionné que l’amendement a été suggéré par une association.

- “(...) Ainsi, selon l’Unef, les prix des produits alimentaires ont augmenté de 1,4 % cette année. (...)” est **non-source**.

  L’amendement n’établit pas de lien explicite entre le dépôt de l’amendement et cette organisation. Il cite simplement une donnée extérieure.

- “(...) Le présent amendement avait été adopté par la Commission du développement durable et de l'aménagement du territoire.” est **non-source**.

  Cette Commission est une commission permanente de l’Assemblée Nationale. Ce n’est pas une institution extérieure à la représentation politique.

- “(...) Cet amendement a été travaillé avec Départements de France.” est **non-source**.

  Départements de France est une association d'élus locaux. Elle fédère des hommes et femmes exerçant un mandat de représentation politique dans le cadre de leur fonction. D'après notre définition et celle de la HATVP, cette association ne peut pas être qualifiée de représentant d'intérêt. Une liste de ces associations peut être trouvée ici.

Étape 3 : annoter les jeux de données

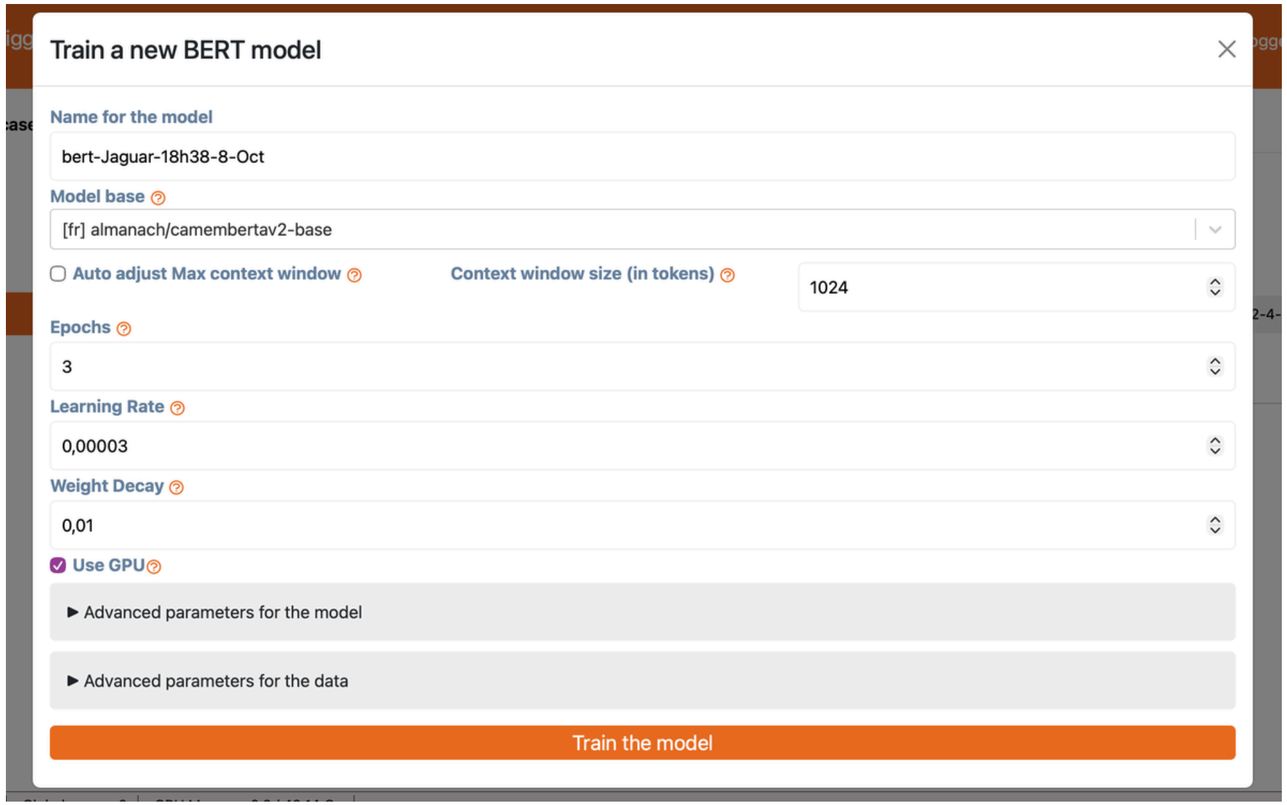
Maintenant que notre codebook est fixé, on peut annoter nos trois jeux de données.
Mêmes possibilités : annotation aléatoire, puis augmentée (search, active learning)



Étape 4 : entraîner des modèles

Choisir un ou des modèles dont les caractéristiques correspondent à nos données.

cf. documentation sur Hugging Face



On essaie **CamembertaV2base** et **ModernCamemBERTbase**

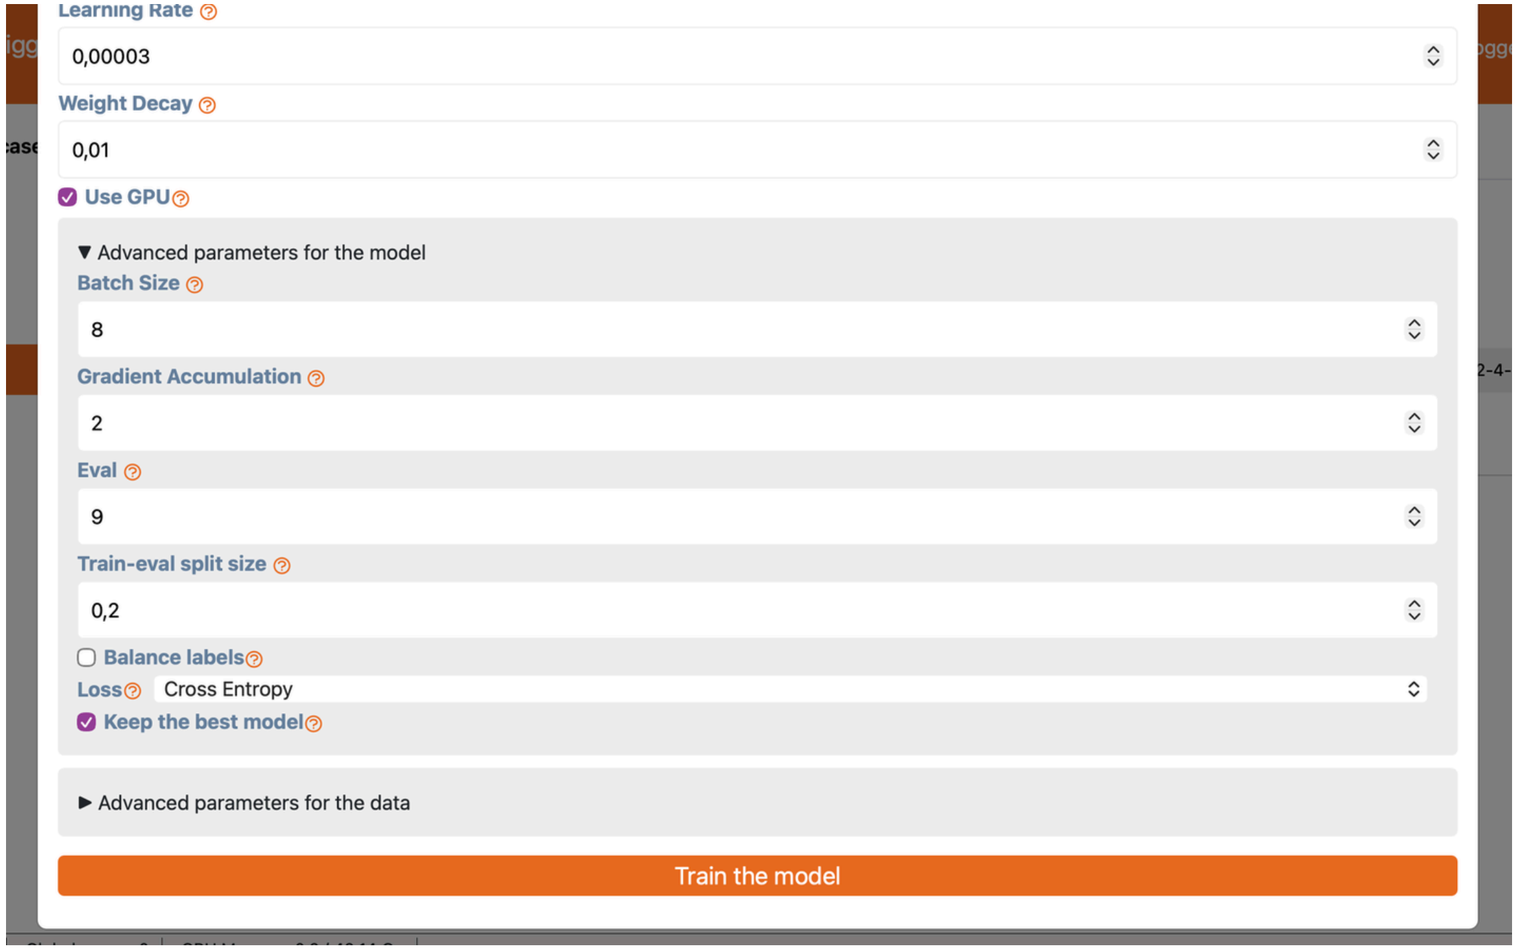
- Francophones
- Fenêtre de contexte de +1024 tokens
- Données d’entraînement conviennent

Étape 4 : entraîner des modèles

Augmenter

- Batch Size*
- Gradient Accumulation**

car 1024 tokens par texte.



*Batch Size = nombre d'exemples que le modèle traite à la fois (en mémoire).

**Gradient Accumulation = nombre de batch additionnés pour modifier les poids.



Étape 4 : entraîner des modèles

Trois informations utiles sur l’entraînement du modèle.

Étape 4 : entraîner des modèles

Trois informations utiles sur l'entraînement du modèle.

1) La matrice de confusion

		Predicted		
		source	non-source	Total
Truth	source	33	2	35
	non-source	6	79	85
	Total	39	81	120

Vérifier que l'erreur ne provient pas d'une erreur d'annotation →



Étape 4 : entraîner des modèles

Trois informations utiles sur l'entraînement du modèle.

2) Les scores de performance

Macro F1 score on Train-Eval set : **0.922**

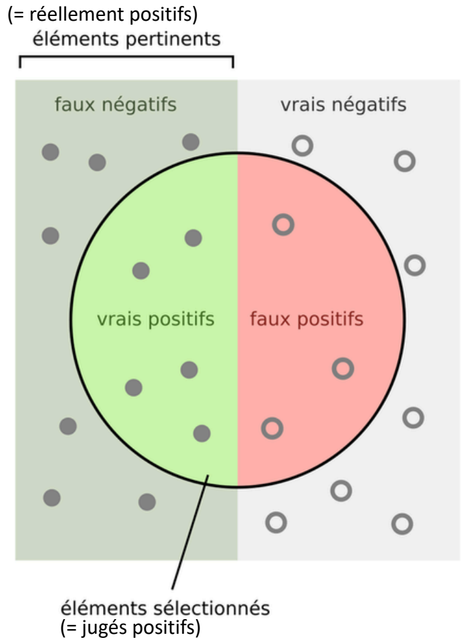
		Predicted		
		source	non-source	Total
Truth	source	33	2	35
	non-source	6	79	85
	Total	39	81	120

	Recall	Precision	F1
source	0.943	0.846	0.892
non-source	0.929	0.975	0.952

Show wrong predictions | Download as JSON

Parameters | Rename

Focus : Que signifient les scores ?



Combien d'éléments sélectionnés sont pertinents ?

$$\text{Précision} = \frac{\text{vrais positifs}}{\text{éléments sélectionnés}}$$

proche de 1 = le modèle ne sélectionne presque que des éléments pertinents.

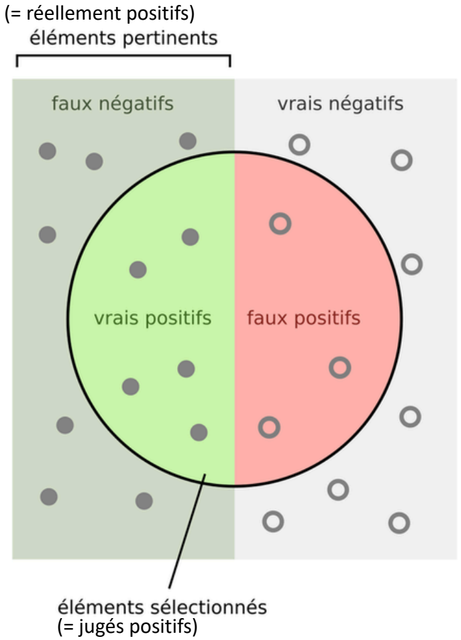
Combien d'éléments pertinents sont sélectionnés ?

$$\text{Rappel} = \frac{\text{vrais positifs}}{\text{éléments pertinents}}$$

proche de 1 = le modèle sélectionne presque tous les éléments pertinents.

	Recall	Precision
source	0.943	0.846
non-source	0.929	0.975

Focus : Que signifient les scores ?



Combien d'éléments sélectionnés sont pertinents ?

$$\text{Précision} = \frac{\text{vrais positifs}}{\text{éléments sélectionnés}}$$

proche de 1 = le modèle ne sélectionne presque que des éléments pertinents.

Combien d'éléments pertinents sont sélectionnés ?

$$\text{Rappel} = \frac{\text{vrais positifs}}{\text{éléments pertinents}}$$

proche de 1 = le modèle sélectionne presque tous les éléments pertinents.

	Recall	Precision	F1
source	0.943	0.846	0.892
non-source	0.929	0.975	0.952

moyenne harmonique de recall et precision

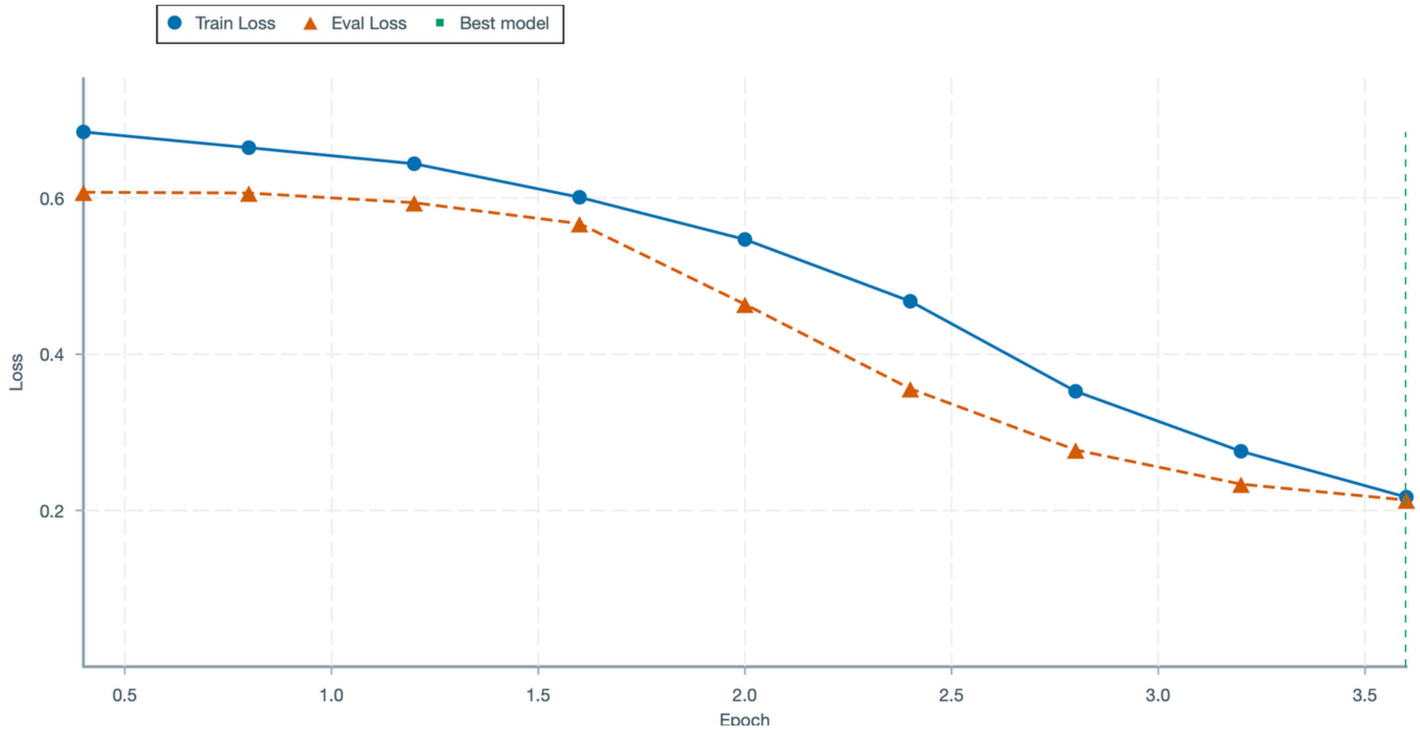
moyenne des F1 de chaque label

Macro F1 score on Train-Eval set : **0.922**

Étape 4 : entraîner des modèles

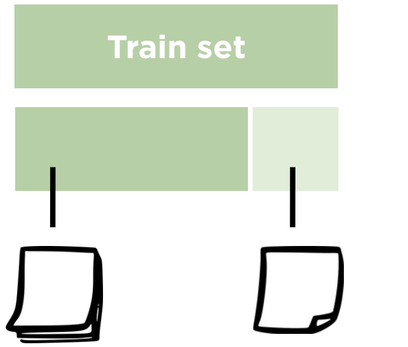
Trois informations utiles sur l’entraînement du modèle.

3) Les courbes de perte (loss curves)



Focus : Que signifient les courbes de perte ?

Évolution de la fonction de perte sur les train et train-eval sets en fonction des époques.

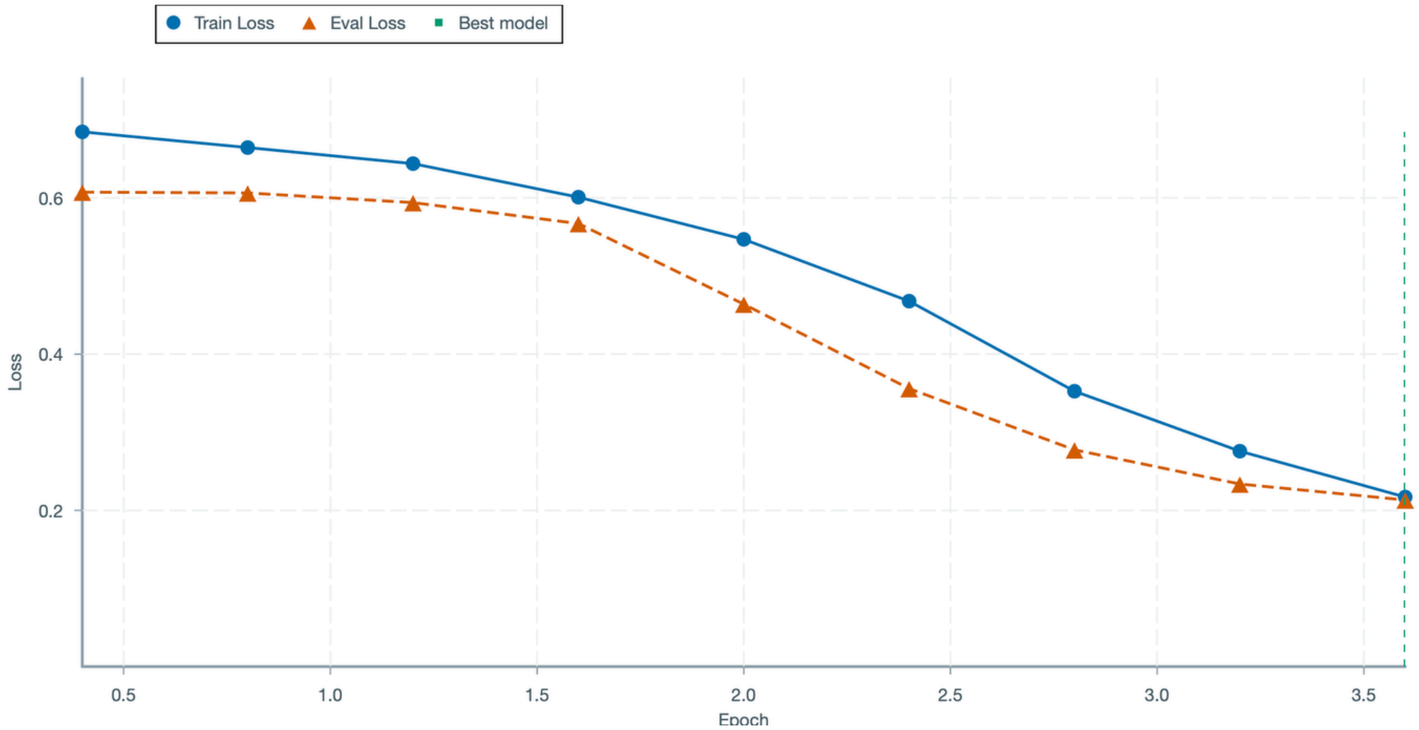


Train Set

Données d'apprentissage du modèle.

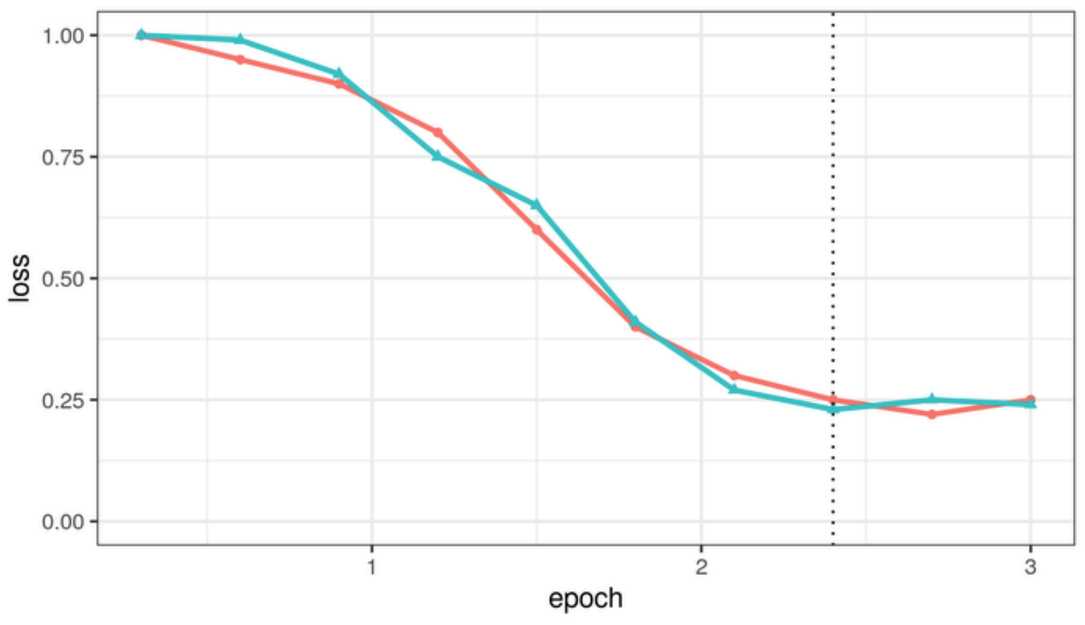
Train-Eval Set

Données pour évaluer le modèle à chaque étape d'entraînement.

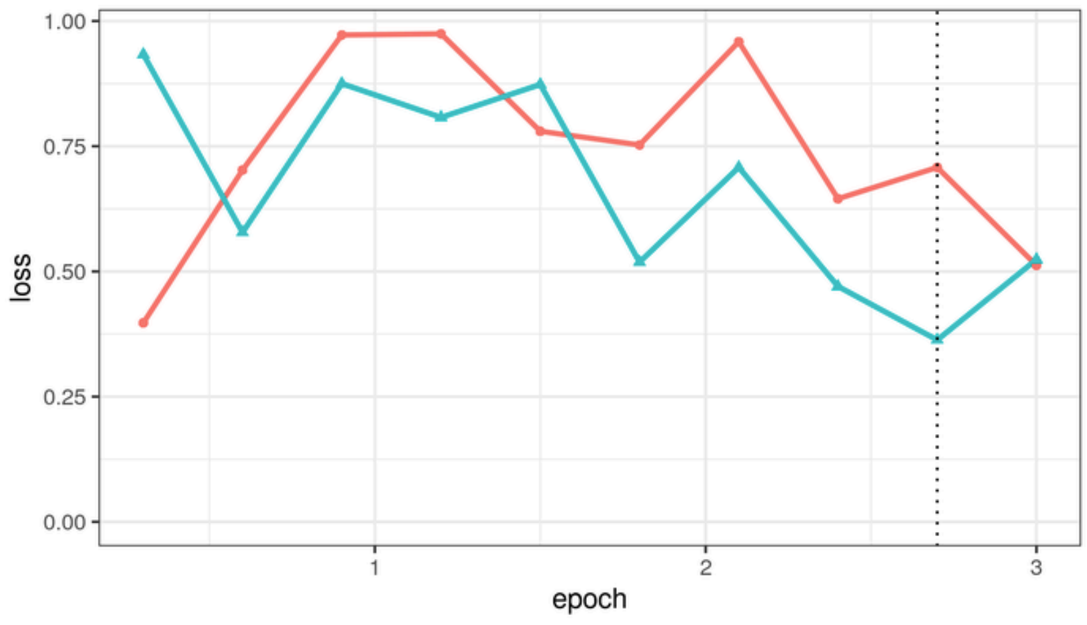


Focus : Que signifient les courbes de perte ?

Apprentissage recherché



Apprentissage trop rapide

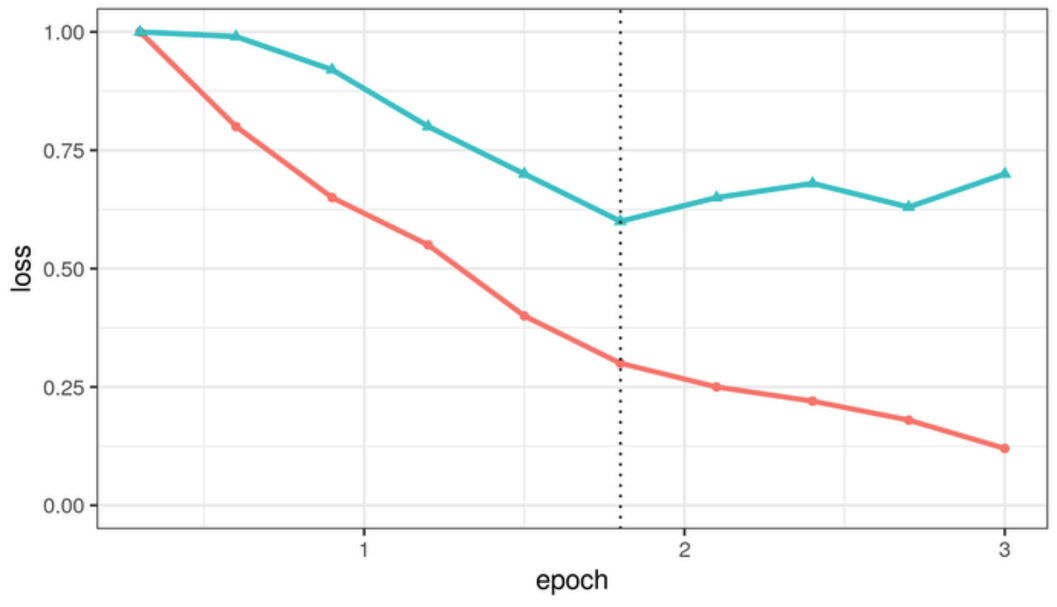


Train loss
Train-Eval loss

- learning rate plus petit
- utiliser des batches de plus grande taille
- annoter plus de données

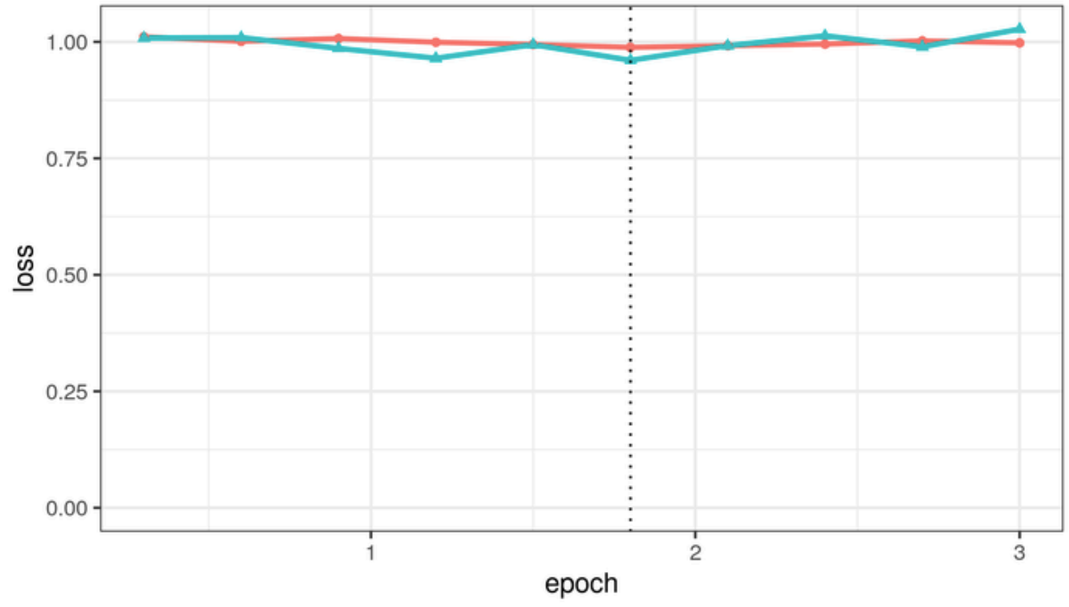
Focus : Que signifient les courbes de perte ?

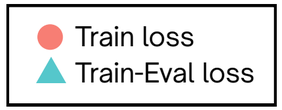
Overfitting
(mémorisation du train set)



- learning rate plus petit
- utiliser des batches de plus grande taille
- annoter plus de données

Underfitting
(pas assez d'apprentissage)





- learning rate plus grand
- utiliser des batches de plus petite taille
- annoter plus de données

Étape 4 : entraîner des modèles

Modèle A

CamembertaV2base
1024 tokens
8 batch size
2 gradient acc
4 époques

Macro F1 score on Train-Eval set : **0.922**

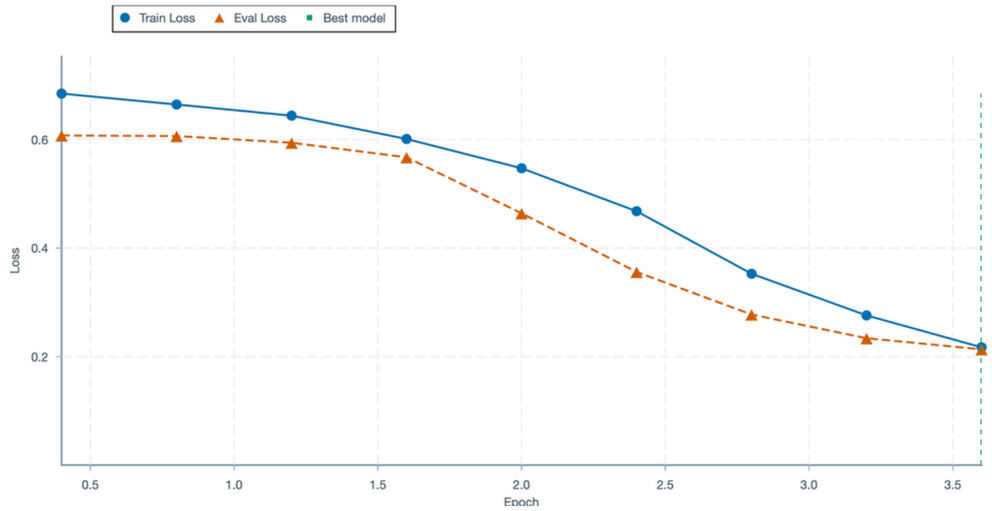
		Predicted		
		source	non-source	Total
Truth	source	33	2	35
	non-source	6	79	85
	Total	39	81	120

	Recall	Precision	F1
source	0.943	0.846	0.892
non-source	0.929	0.975	0.952

Show wrong predictions | Download as JSON | Parameters | Rename

Bons choix, mais il semblerait que le modèle pourrait encore apprendre.

=> Augmenter le nombre d’époques.



Étape 4 : entraîner des modèles

Modèle B

CamembertaV2base
1024 tokens
8 batch size
2 gradient acc
6 époques

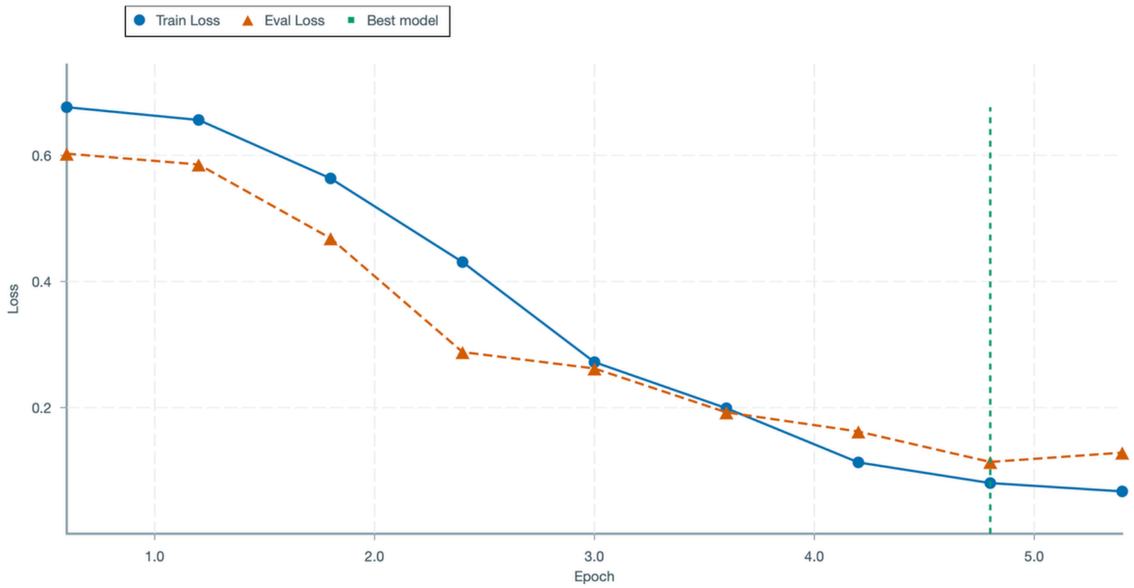
Macro F1 score on Train-Eval set : **0.96**

		Predicted		
		source	non-source	Total
Truth	source	34	1	35
	non-source	3	82	85
	Total	37	83	120

	Recall	Precision	F1
source	0.971	0.919	0.944
non-source	0.965	0.988	0.976

Show wrong predictions | Download as JSON | Parameters | Rename

Il a effectivement davantage appris.

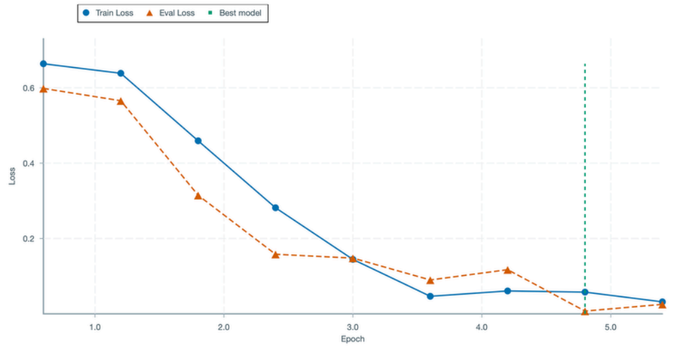


Étape 4 : entraîner des modèles

On peut essayer quelques autres modèles.

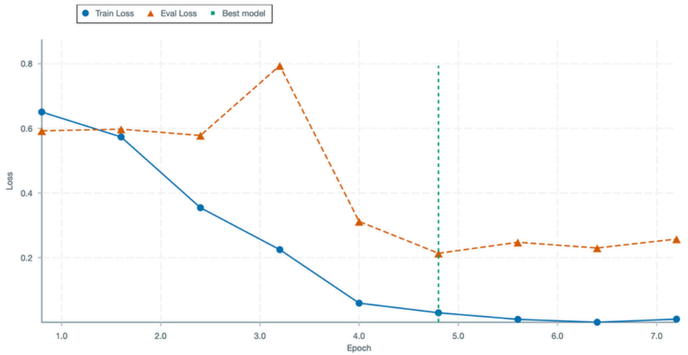
Modèle C

CamembertaV2base
1024 tokens
8 batch size
1 gradient acc
5 époques



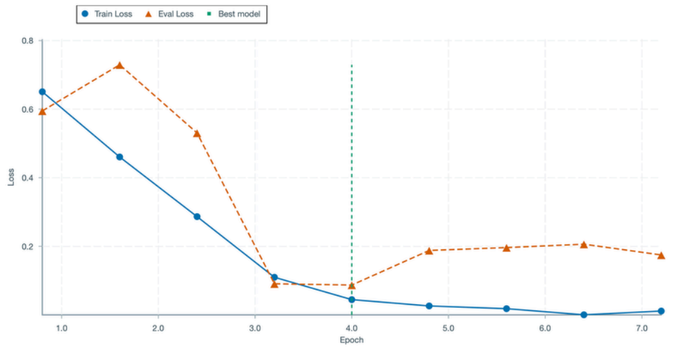
Modèle D

ModernCamemBERTbase
1024 tokens
8 batch size
2 gradient acc
8 époques



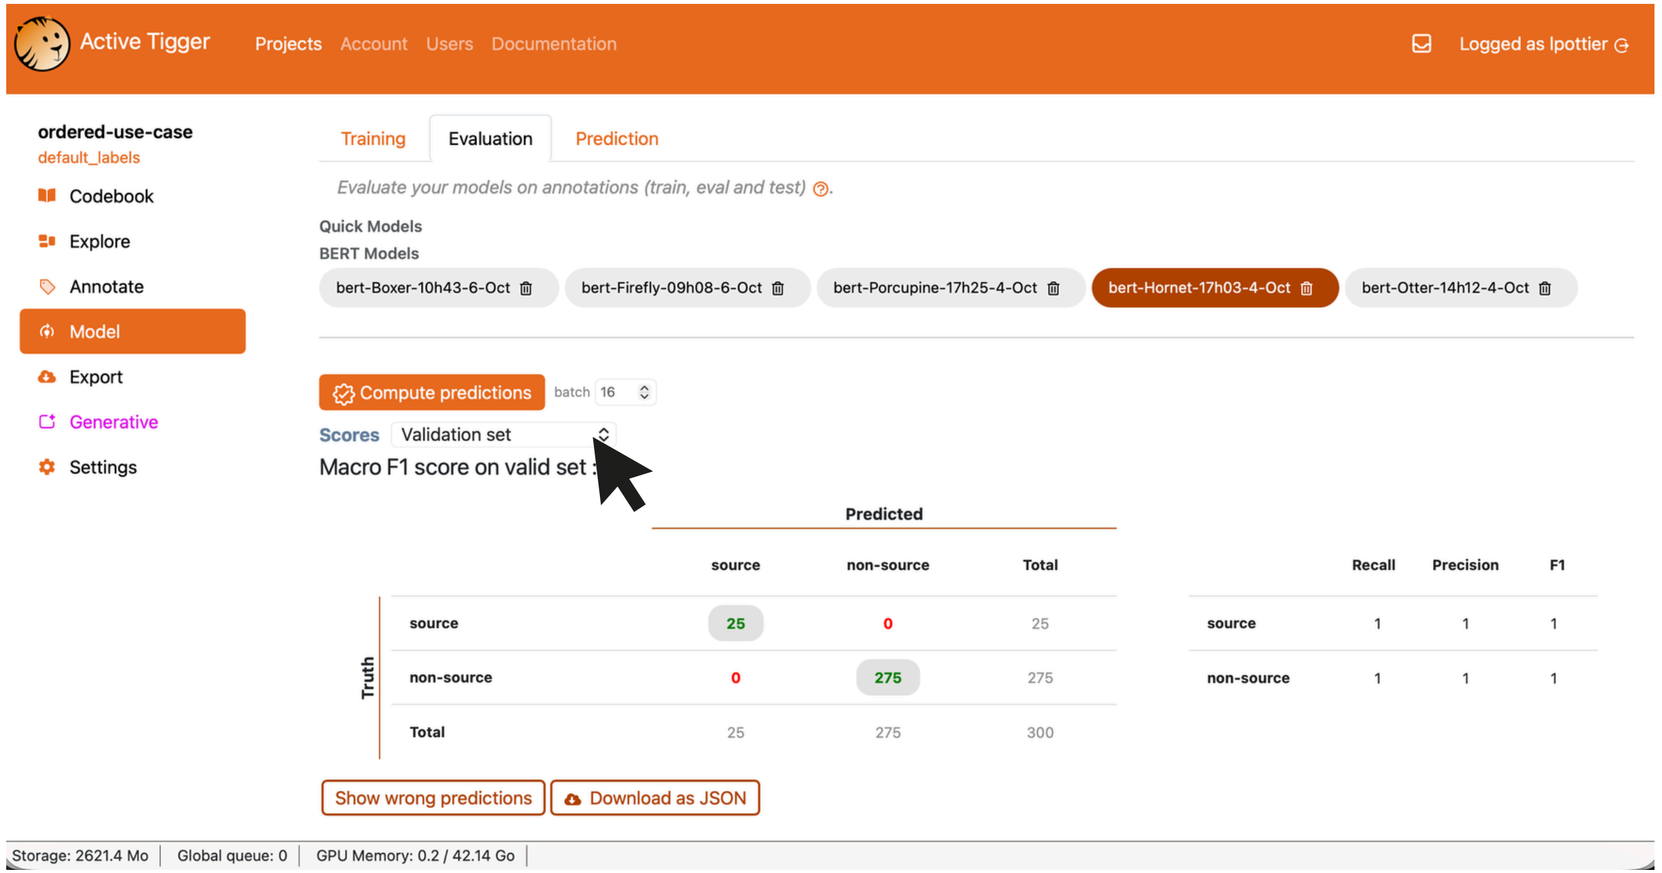
Modèle E

ModernCamemBERTbase
1024 tokens
8 batch size
1 gradient acc
8 époques



Étape 5 : sélectionner un modèle

Comparer les scores sur le set de validation.



Étape 5 : sélectionner un modèle

Modèle A Macro F1 score on valid set : **0.965**

	Recall	Precision	F1
source	0.88	1	0.936
non-source	1	0.989	0.995

Modèle B Macro F1 score on valid set : **1**

	Recall	Precision	F1
source	1	1	1
non-source	1	1	1

Modèle C Macro F1 score on valid set : **0.979**

	Recall	Precision	F1
source	1	0.926	0.962
non-source	0.993	1	0.996

Modèle D Macro F1 score on valid set : **0.959**

	Recall	Precision	F1
source	1	0.862	0.926
non-source	0.985	1	0.993

Modèle E Macro F1 score on valid set : **0.959**

	Recall	Precision	F1
source	1	0.862	0.926
non-source	0.985	1	0.993

Étape 5 : sélectionner un modèle

Modèle A Macro F1 score on valid set : **0.965**

	Recall	Precision	F1
source	0.88	1	0.936
non-source	1	0.989	0.995

Modèle B Macro F1 score on valid set : **1**

	Recall	Precision	F1
source	1	1	1
non-source	1	1	1

Modèle C Macro F1 score on valid set : **0.979**

	Recall	Precision	F1
source	1	0.926	0.962
non-source	0.993	1	0.996

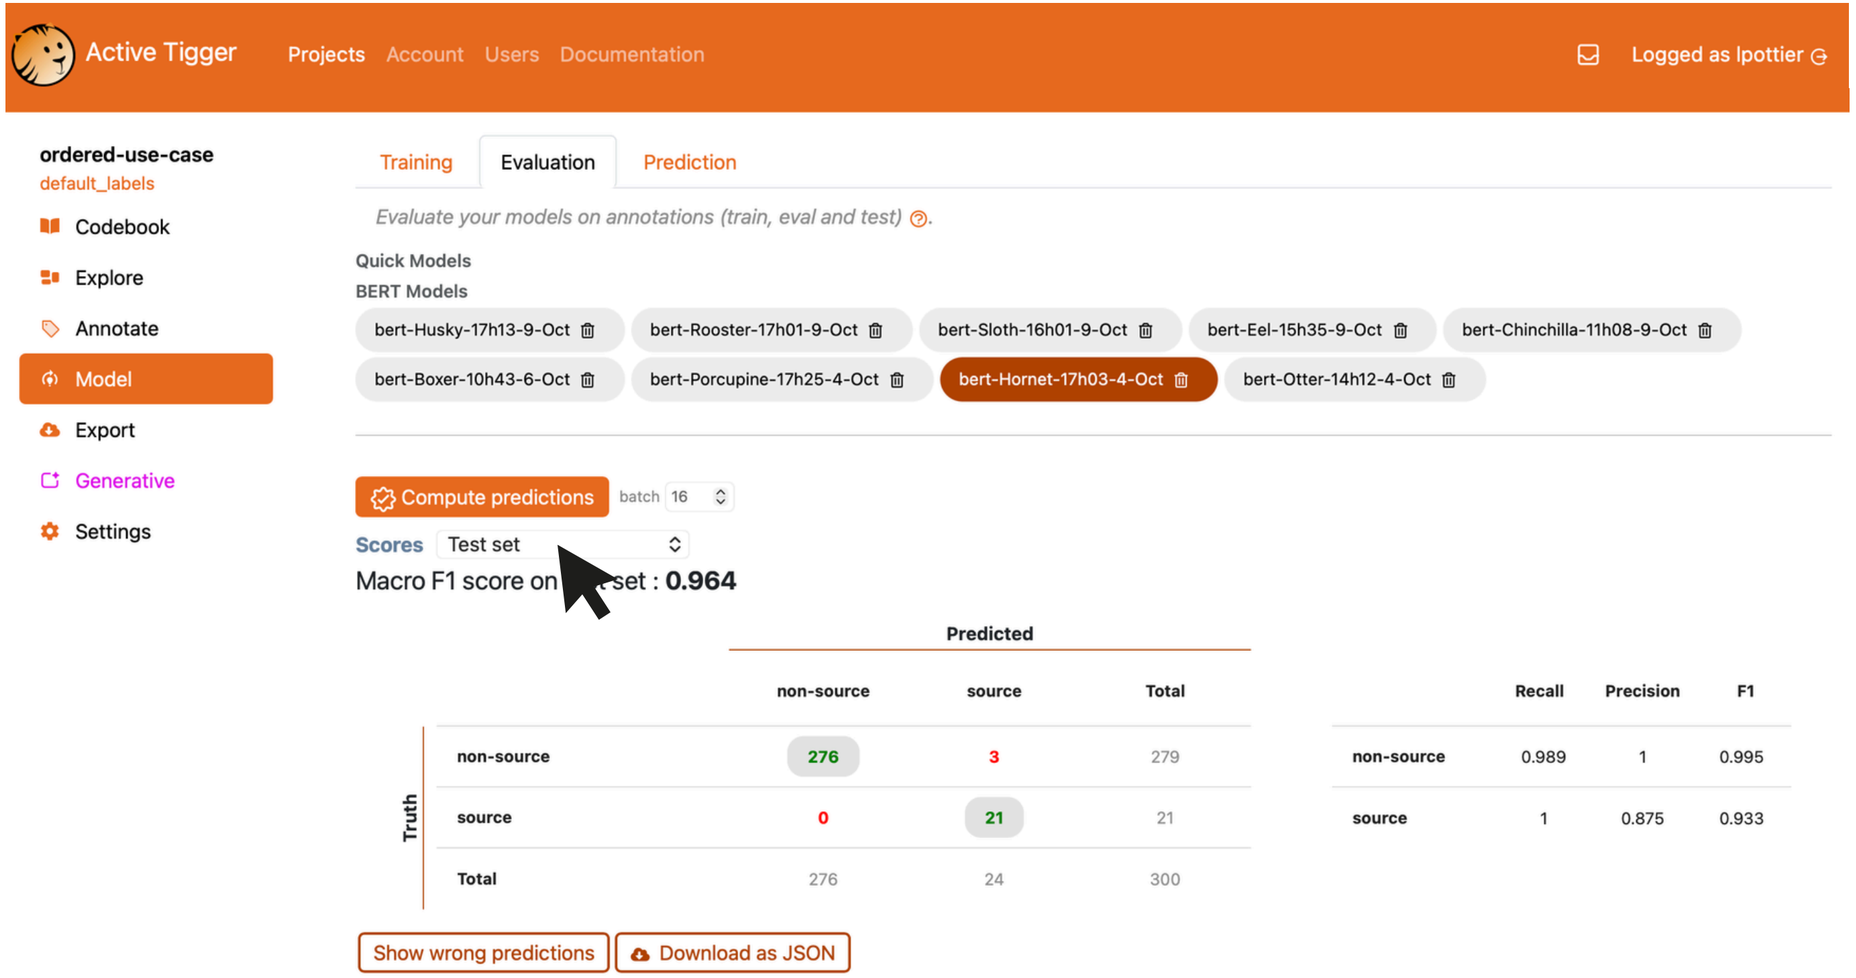
Modèle D Macro F1 score on valid set : **0.959**

	Recall	Precision	F1
source	1	0.862	0.926
non-source	0.985	1	0.993

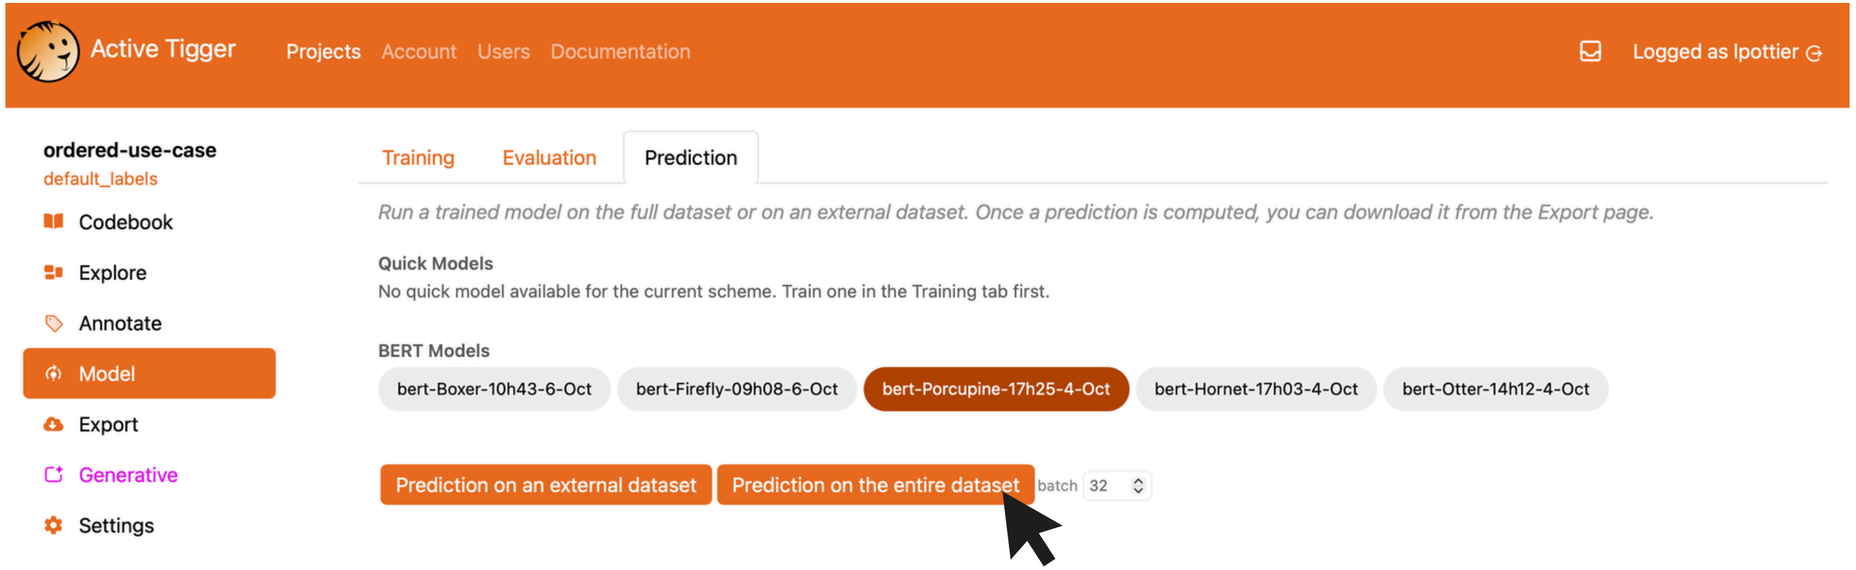
Modèle E Macro F1 score on valid set : **0.959**

	Recall	Precision	F1
source	1	0.862	0.926
non-source	0.985	1	0.993

Étape 6 : évaluer le modèle



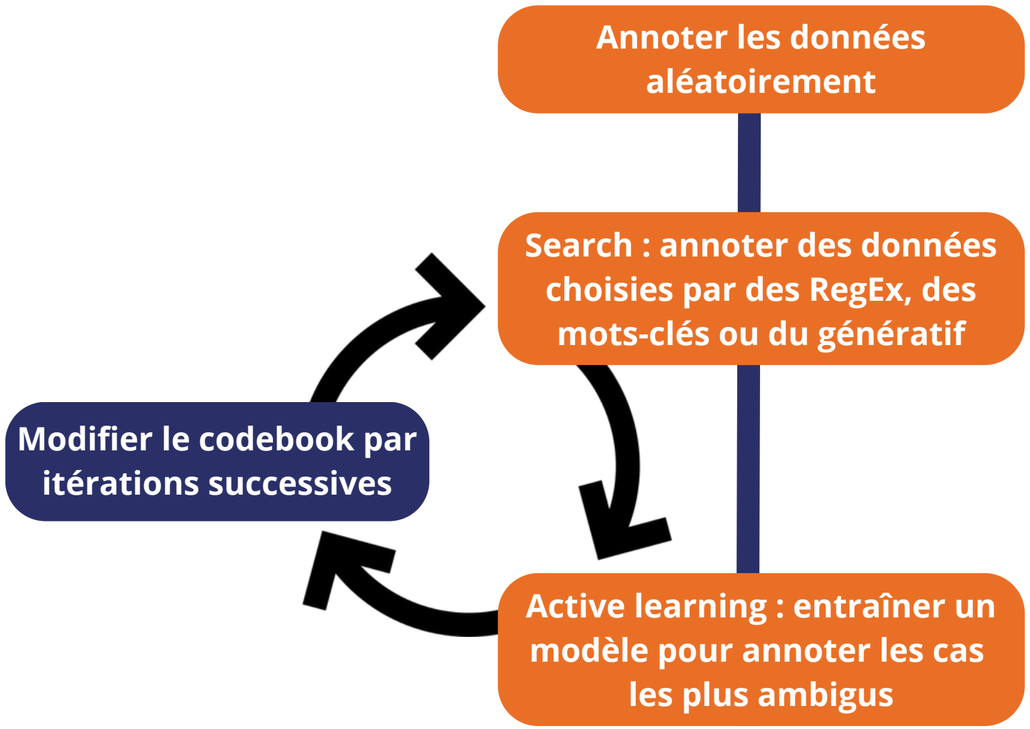
Étape 7 : prédire sur l’ensemble des données



Rappel : le workflow d’un projet ActiveTigger

Étape 1 : Création du projet

Étape 2 : Définir son codebook



Étape 3 : Annoter les jeux de données

Étape 4 : Entraîner des modèles



Étape 5 : Sélectionner un modèle



Étape 6 : Évaluer le modèle



Étape 7 : Prédire sur l’ensemble des données

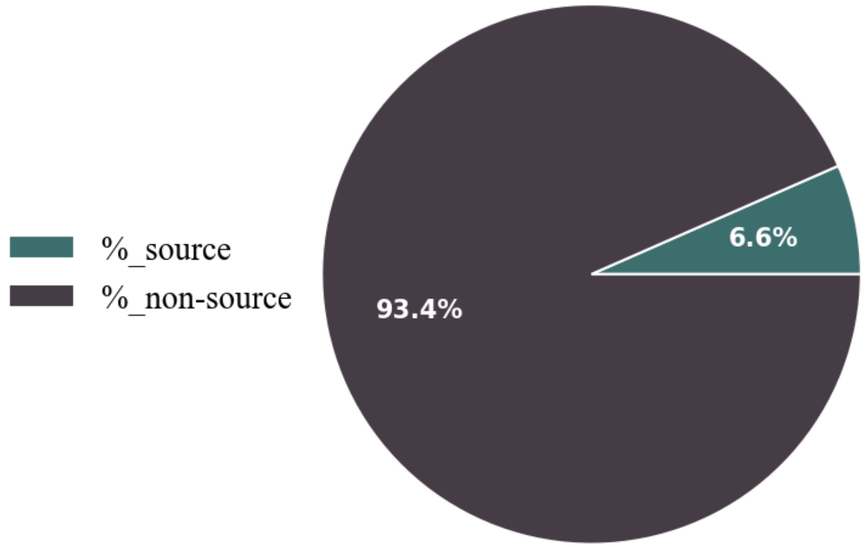


Conclusion

Quelques résultats

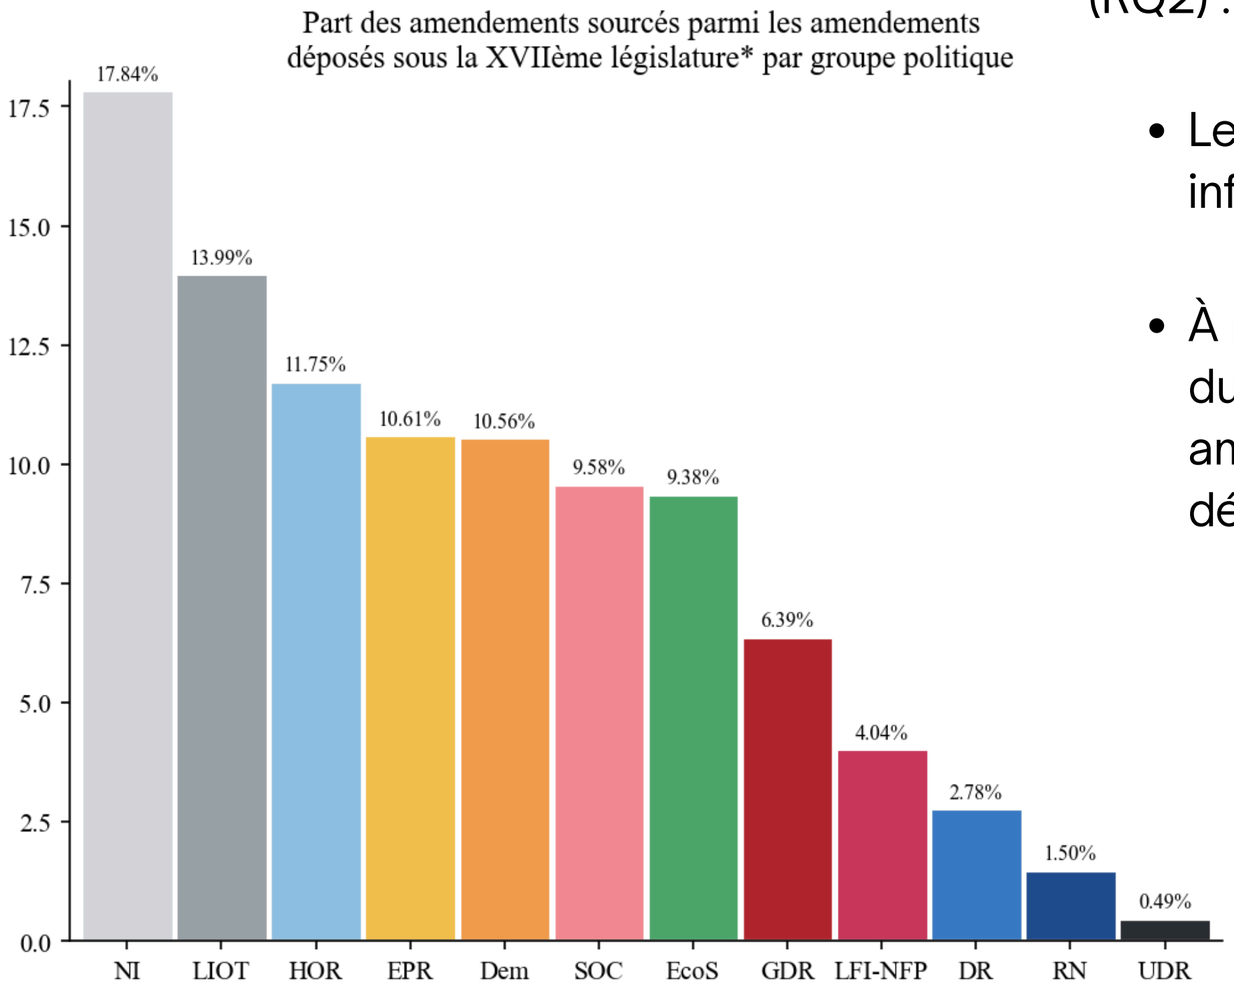
(RQ1) : Pratique minoritaire mais non marginale.

Répartition des amendements de la XVIIème législature* selon leur sourcing (en %)



*à l'exclusion des amendements dont l'exposé sommaire est null ou d'une longueur >1024 tokens.

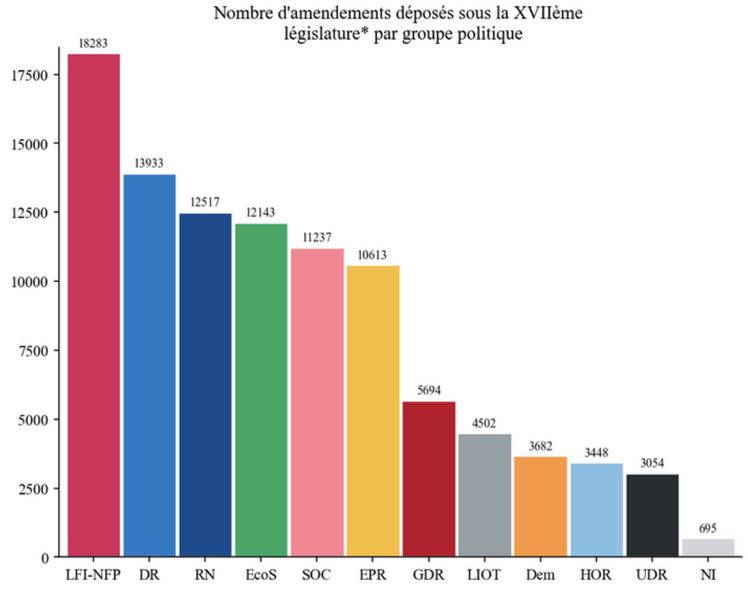
Quelques résultats



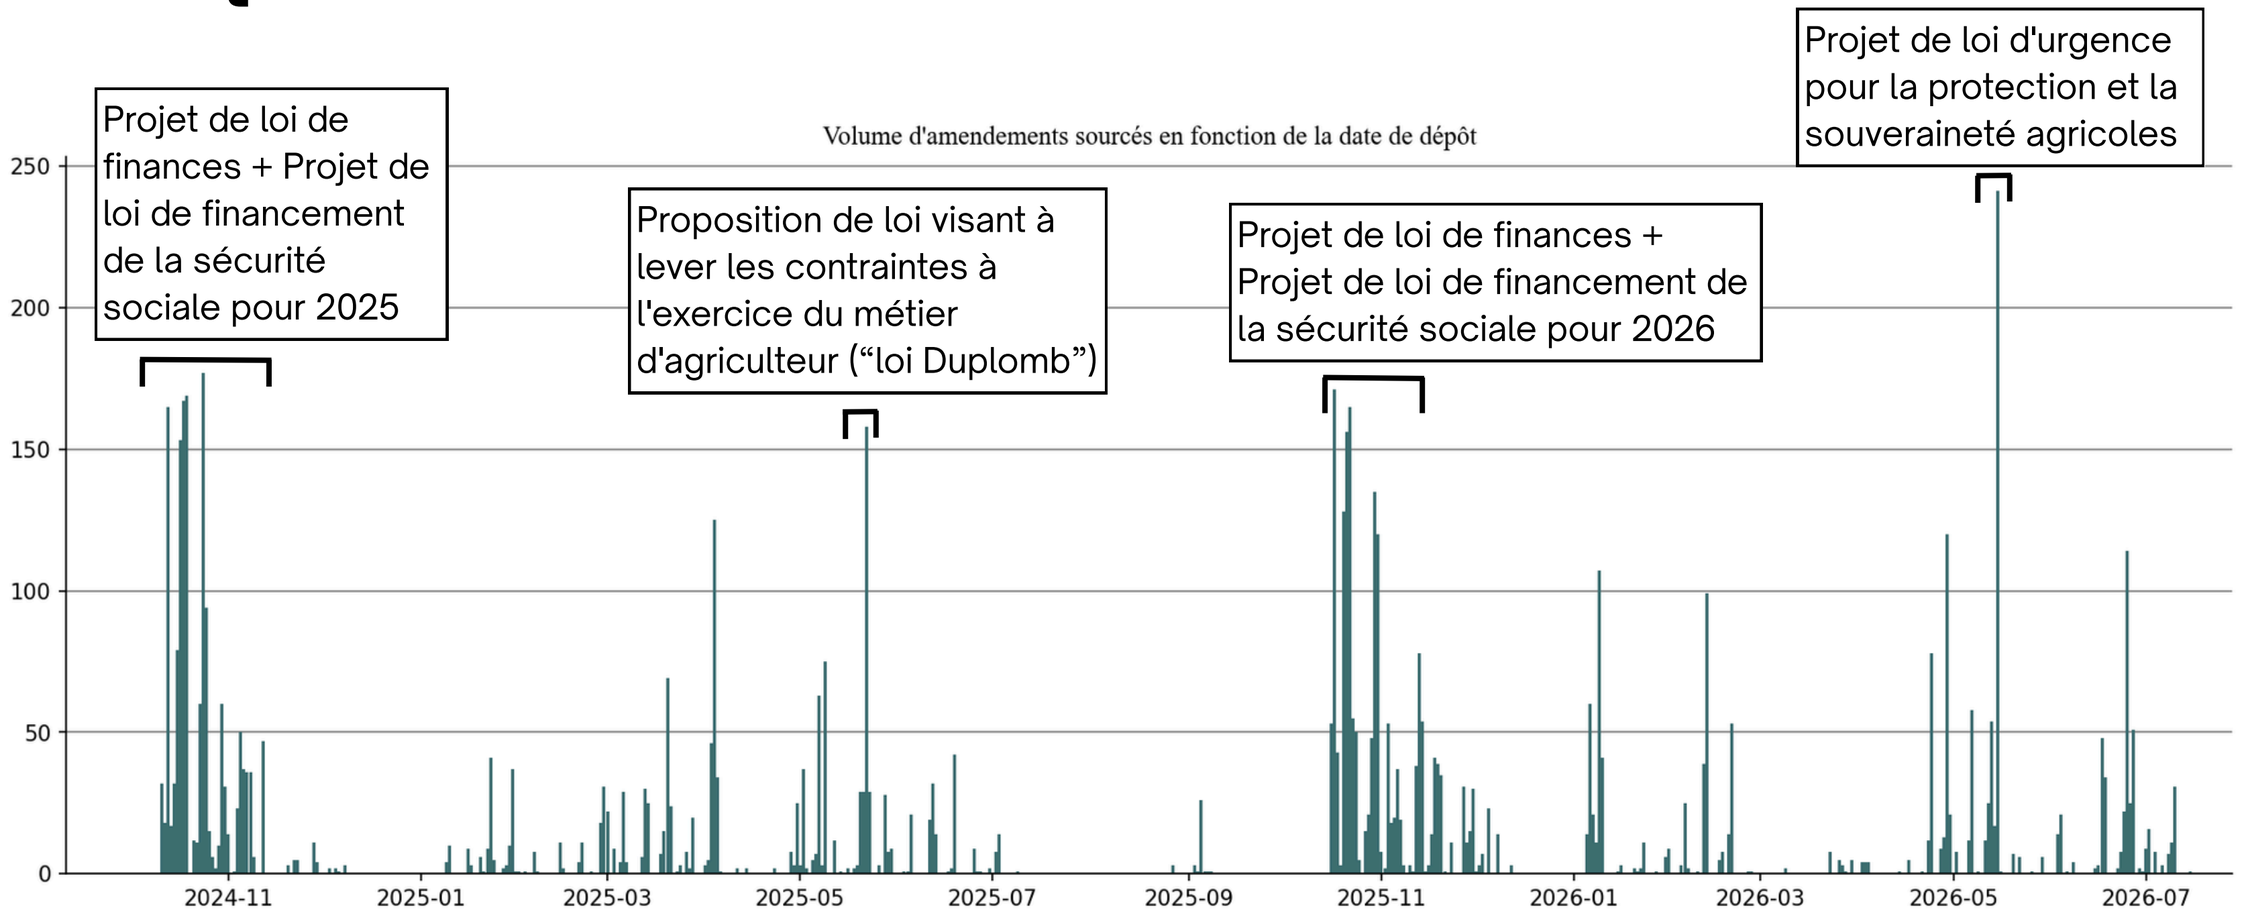
*à l'exclusion des amendements dont l'exposé sommaire est null ou d'une longueur >1024 tokens.

(RQ2) : Différence substantielle entre groupes politiques.

- Les NI et LIOT sont-ils plus soumis à influence ou plus transparents ?
- À mettre au regard du volume des amendements déposés

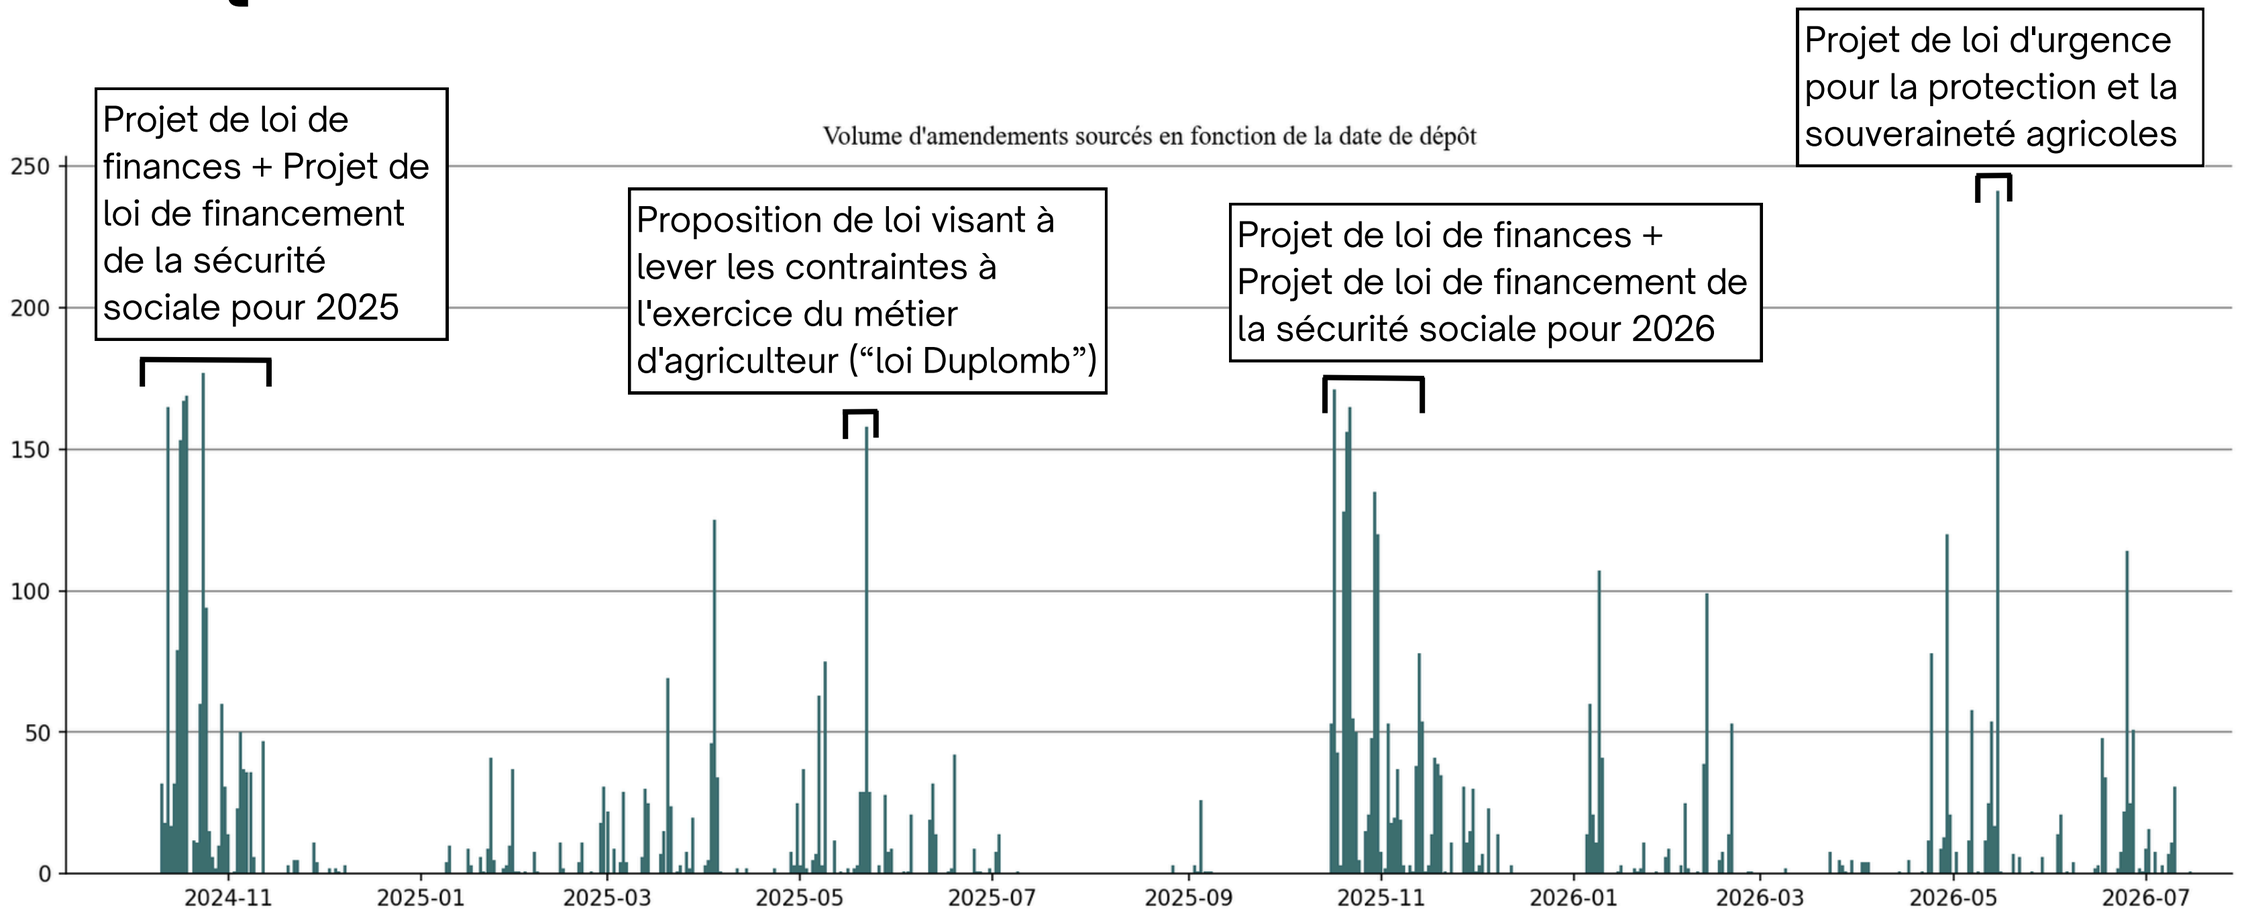


Quelques résultats



(RQ3) : davantage de sourcing lors des grands moments parlementaires (PLF) et sur des textes relatifs à l’agriculture

Quelques résultats



(RQ3) : davantage de sourcing lors des grands moments parlementaires (PLF)
et sur des textes relatifs à l’agriculture ⟶ qui ? pourquoi ?

Intérêt, limites

Est-ce qu’un modèle génératif aurait pu le faire ?

Si le guide d’annotation est déjà optimal, oui.

Ce n’était pas le cas ici

- Annoter nous permet d’avoir une **meilleure connaissance des données** et d’affiner / de remettre en question notre guide d’annotation

Intérêt, limites

Est-ce qu’un modèle génératif aurait pu le faire ?

Par ailleurs, mettre en perspective la nature de notre cas :

- **Simplicité de la tâche** (peu d’appréciation subjective)
- **Absence de sensibilité des données**
- **Coût temporel limité** (peu d’annotations)

Et ne pas ignorer :

- **Coûts économique, environnemental**
- **Réplicabilité**

Intérêt, limites

Ce qu’on aurait pu ajouter ou faire différemment :

- **Exploration préalable** des données via les outils intégrés dans ActiveTigger
- **Plus d’annotations** :
  - validation et test sets (meilleur F1)
  - train set pour la catégorie “source”
- **Annotation croisée** d’une partie des données (accord inter-annotateur)
- **Annotation manuelle** des 664 données de +1024 tokens retirées du dataset.



Merci !

Demande de compte, documentation, lien GitHub, lien Discord :
https://activetigger.com